IBM watsonx.ai

Atelier pratique – Introduction à l'IA Générative avec watsonx.ai



Noe Samaille
noe.samaille@ibm.com

Contenu

1. Présentation de watsonx.ai 3
2. À propos de cet atelier 5
2.1 Démenti 5
3. Conditions préalables et mise en route 6
4. Fonction de chat dans le laboratoire d'invite 8
4.1 Accès à la fonction de chat sur la console watsonx.ai 8
4.2 Accès à la conversation dans le laboratoire d'invite 12
4.3 Exemple de session de chat 17
4.4 Différents LLM pris en charge dans watsonx.ai Chat 29
4.5 Génération augmentée de chat et de récupération (RAG) 40
4.5.1 Chat dans un cas d'utilisation RAG – méthode en ligne 40
4.5.2 Discuter avec des documents 43
4.5.3 Explorer les options de chat avec Documents 52
4.6 Un examen plus approfondi des composants internes de watsonx.ai : utilisation de la mémoire et garde-fous 57
4.6.1 Gestion de la mémoire 57
4.6.2 Implémentation de la mémoire watsonx.ai IBM 61
4.6.3 Garde-fous de l'IA dans un chat 67
Annexe A. Historique des révisions 77

© 2024 Société IBM

1. Présentation de watsonx.ai

Watsonx.ai est un composant essentiel de WatsonX, la plateforme d'IA et de données d'entreprise d'IBM, conçue pour multiplier l'impact de l'IA dans une entreprise.

La plateforme watsonx comporte trois composants puissants :

- watsonx.ai, un studio pour les nouveaux modèles de base, l'IA générative et l'apprentissage automatique (IA traditionnelle)
- Watsonx.Data, un datalakehouse adapté à l'usage qui offre la flexibilité d'un datalake avec les performances d'un data wharehouse.
- watsonx.governance, une boîte à outils qui permet des flux de travail d'IA conçus avec responsabilité, transparence et explicabilité.

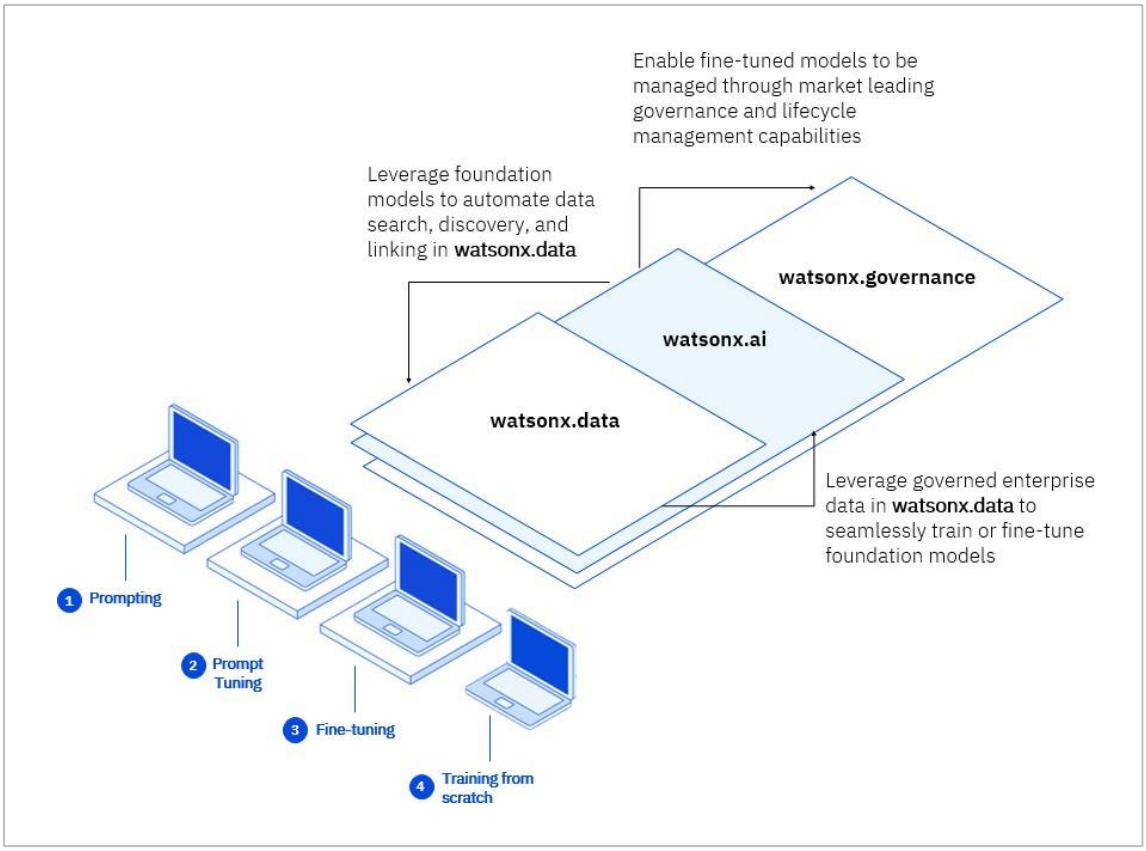


Figure 1 : Plateforme IBM watsonx

Le composant watsonx.ai (l'objet de cet atelier) permet aux entreprises d'entraîner, de valider, d'ajuster et de déployer des modèles d'IA, qu'il s'agisse d'IA traditionnelle ou d'IA générative. Grâce à watsonx.ai, les entreprises peuvent tirer parti de leurs investissements traditionnels existants dans l'IA et exploiter les innovations et le potentiel de l'IA générative en utilisant des modèles de base pour apporter des

© 2024 Société IBM

l'automatisation et les applications infusées d'IA pour réduire les coûts, améliorer l'efficacité, faire évoluer et accélérer l'impact de l'IA dans leurs organisations.

© 2024 Société IBM

2. À propos de cet atelier

Dans cet atelier : vous allez examiner la fonctionnalité de chat de watsonx.ai. Cette fonction de chat fournit :

- Un point d'entrée facile dans l'IA générative
- Excellents exemples d'IA générative pour fournir une sortie structurée
- Un moyen facile de faire l'expérience de la génération augmentée de récupération

2.1 Démenti

IBM watsonx.ai est développé et publié de manière agile. En plus d'ajouter constamment de nouvelles fonctionnalités, l'interface web est susceptible d'évoluer au fil du temps. Par conséquent, les captures d'écran utilisées dans ce laboratoire peuvent ne pas toujours ressembler exactement à ce que vous voyez. Vous pouvez vous attendre à rencontrer certains des éléments suivants :

- Autres modèles de base dans la liste de la bibliothèque
- Modèles de base supplémentaires disponibles pour un réglage rapide
- Modifications de l'interface utilisateur (emplacement des boutons, texte pour divers champs)
- Onglets/boutons supplémentaires

Ces mises à jour ne devraient pas affecter le fonctionnement du laboratoire, mais soyez patient et prêt à explorer un peu jusqu'à ce que ce laboratoire soit mis à jour.

Cependant, trois changements peuvent affecter les résultats. Par exemple:

- IBM évalue constamment les modèles dans watsonx.ai, et de nouveaux modèles peuvent être ajoutés, et d'autres obsolètes ou supprimés.

- Les modèles sont en cours de réglage. Si les modèles eux-mêmes sont mis à jour, alors Certains résultats peuvent varier.

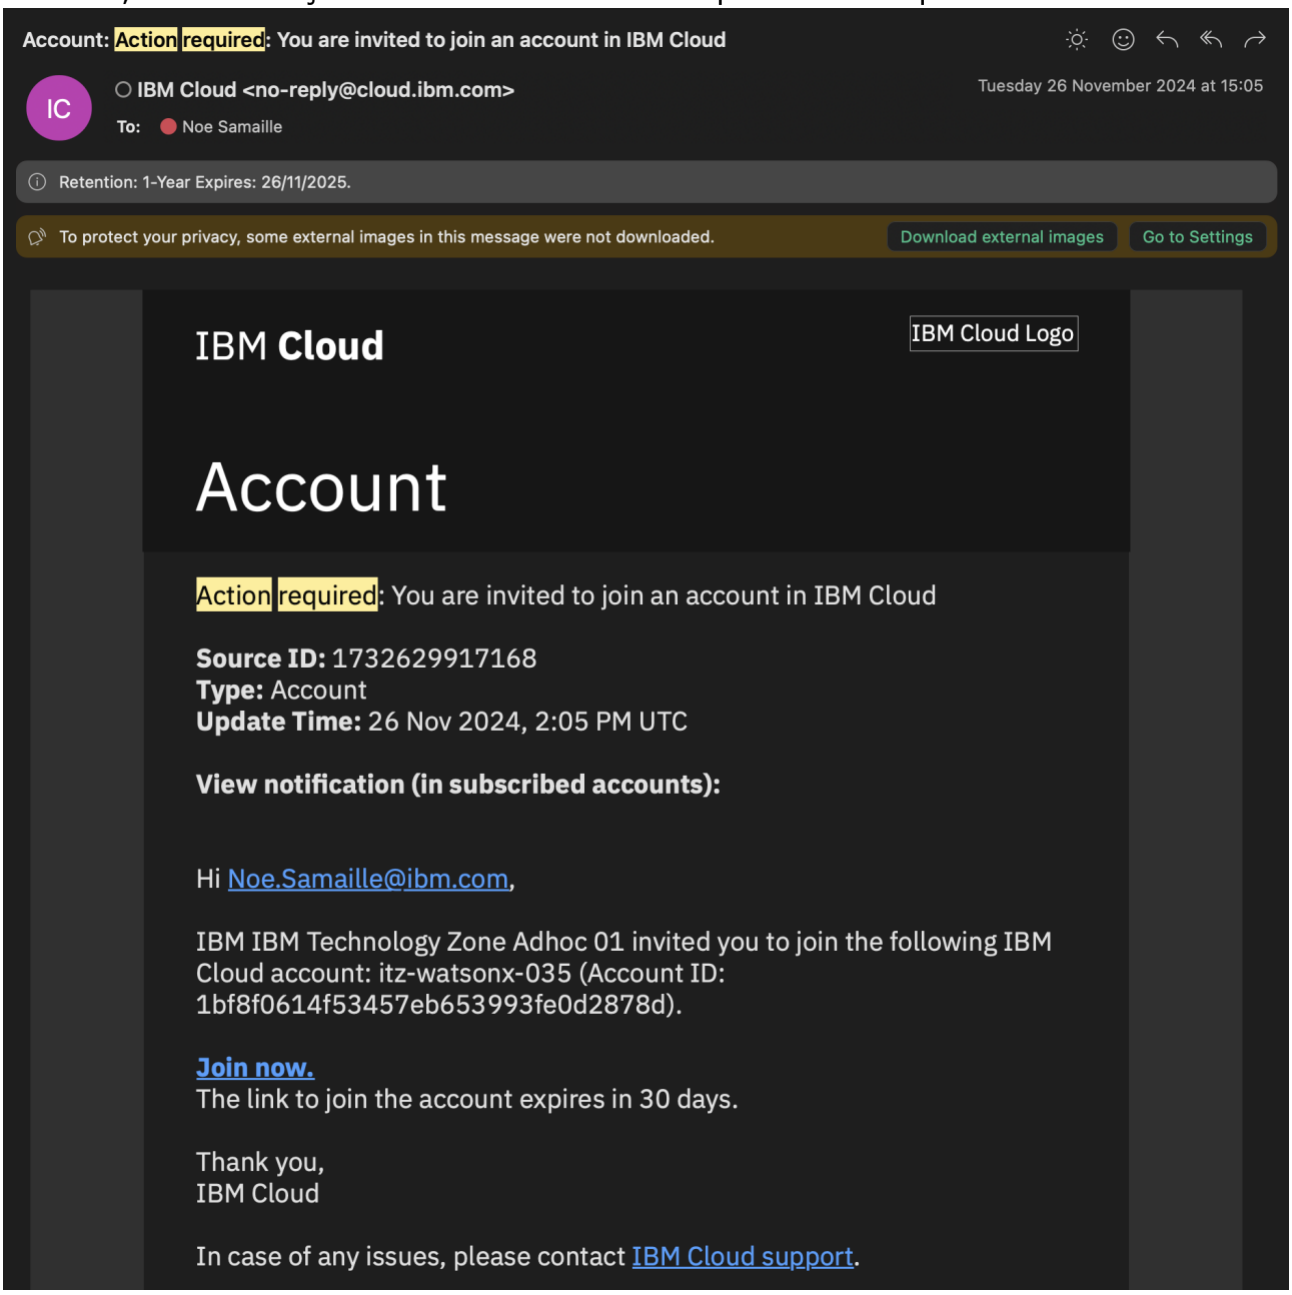
- Les modèles de base peuvent être très sensibles aux entrées. Si vous entrez un texte légèrement différent de celui utilisé par l'exercice (même s'il ne s'agit que d'un seul mot ou d'un ensemble modifié de données étiquetées), le résultat peut être très différent.

© 2024 Société IBM

3. Conditions préalables et mise en route

Vous aurez besoin d'un compte IBM Cloud pour accéder au compte TechZone qui héberge les différents services Watson et Watsonx utilisés dans cet atelier.

Pour cela, vous avez reçu un mail d'invitation à un compte IBM Cloud qui ressemble au suivant.

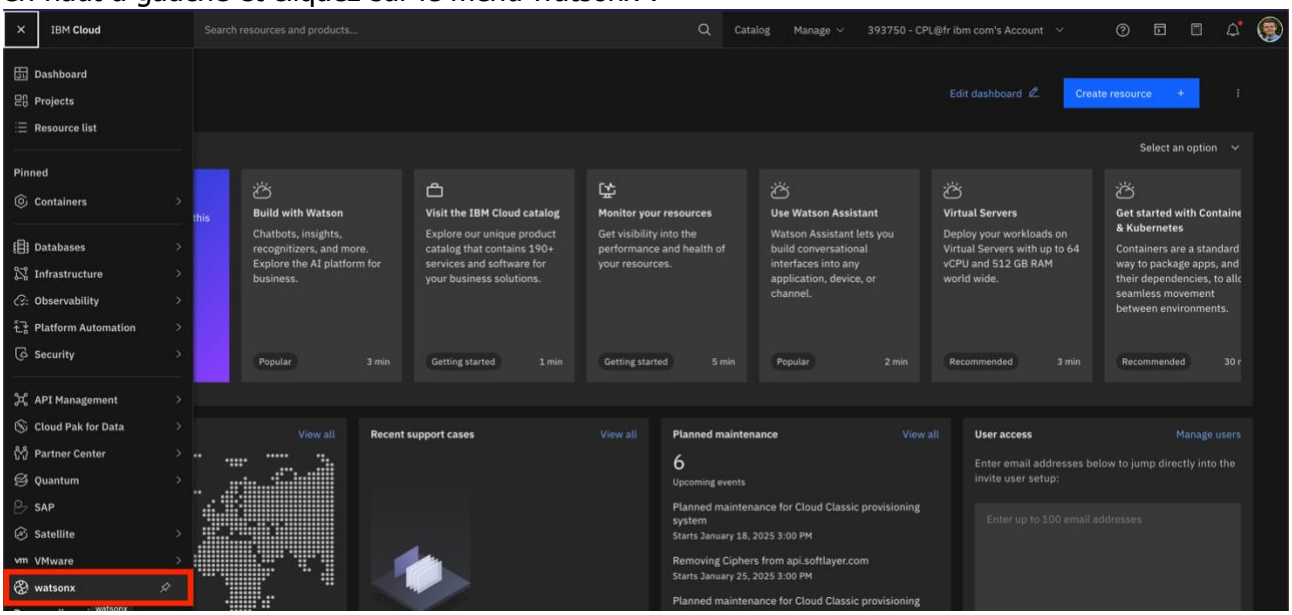


Clickez sur « **Join now** » et suivez les étapes d'inscription.

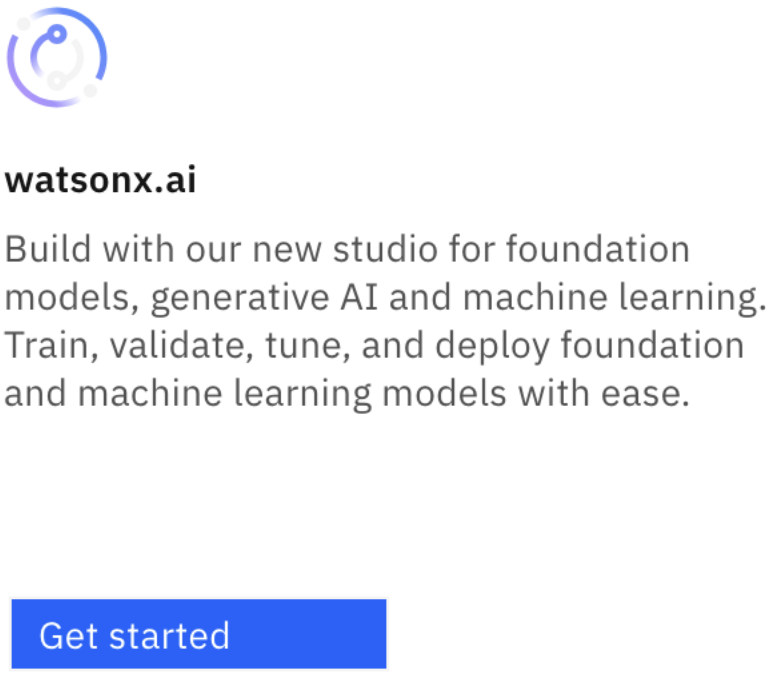
Une fois connecté, vous devriez atterrir dans le tableau de bord IBM Cloud, cliquez sur le menu

© 2024 Société IBM

en haut à gauche et cliquez sur le menu watsonx :



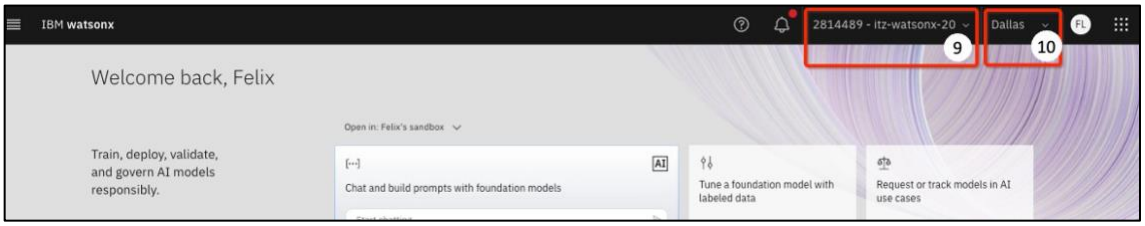
Un fois sur la page watsonx, cliquez sur **Get Started** en dessous de **watsonx.ai** et suivez les étapes en sélectionnant **Dallas** comme région.



Une fois connecté à watsonx.ai, assurez-vous d'utiliser le bon compte : dans cet exemple, il s'agit de ITZ-WATSONX-20.

1. Vérifiez que vous êtes dans la bonne région : dans ce cas, us-south (ou Dallas).

© 2024 Société IBM



Si le compte ou la région est incorrect, cet atelier ne fonctionne pas.

4. Fonction de chat dans le laboratoire d'invite

Il existe différentes façons d'interagir avec watsonx.ai grands modèles de langage (LLM). Dans le laboratoire des outils d'IA générative, vous avez travaillé avec les interfaces structurées et de forme libre. La troisième façon d'interagir avec les grands modèles de langage (LLM) de watsonx.ai consiste à utiliser son interface utilisateur (UI) Chat à partir du Prompt Lab.

Dans le Chat, un utilisateur effectue une interaction de chat avec un LLM (généralement, mais pas exclusivement, un modèle de chat). Le chat est conçu pour améliorer l'expérience des développeurs avec les LLM, en particulier lorsqu'ils développent des applications qui impliquent des interactions utilisateur en temps réel. Les développeurs seraient en mesure d'essayer rapidement différents modèles.

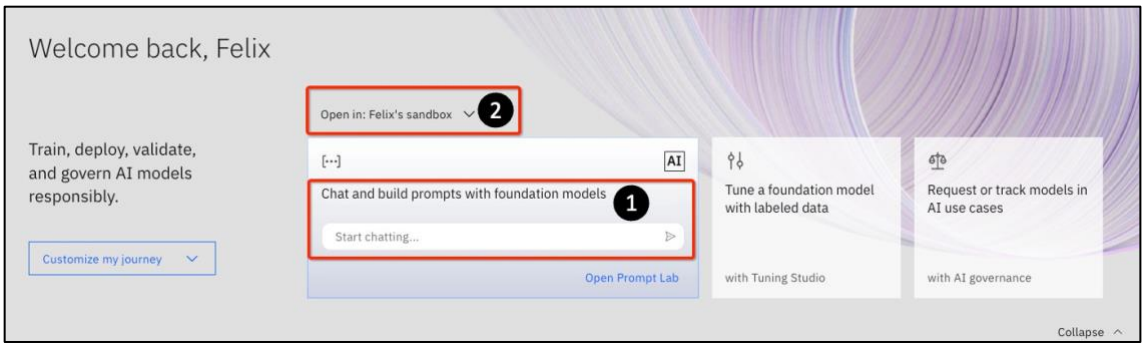
Il existe différents exemples que vous pouvez essayer dans le chat. Vous pouvez prendre l'extrait de code de ces exemples et le personnaliser avec différents modèles et paramètres pour votre cas d'utilisation.

4.1 Accès à la fonction de chat sur la console watsonx.ai

1. La fonction Chat est accessible immédiatement lorsque vous vous connectez à la console watsonx.ai.

2. La fonction Chat est exécutée dans le contexte d'un projet à l'aide de ressources telles que des jetons et des heures d'unité de capacité (CUH) de ce projet. Si vous avez plus d'un projet, watsonx.ai utiliserez par défaut le premier projet de la liste. Vous pouvez sélectionner le projet à utiliser en ouvrant le menu déroulant et en choisissant le projet approprié.

© 2024 Société IBM

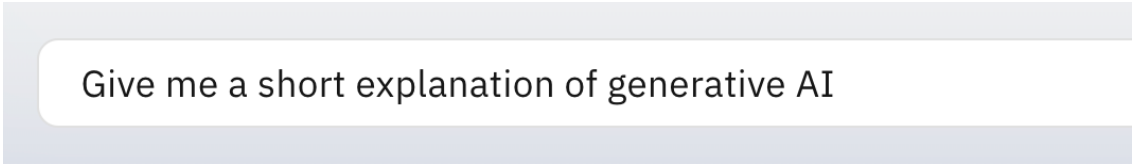


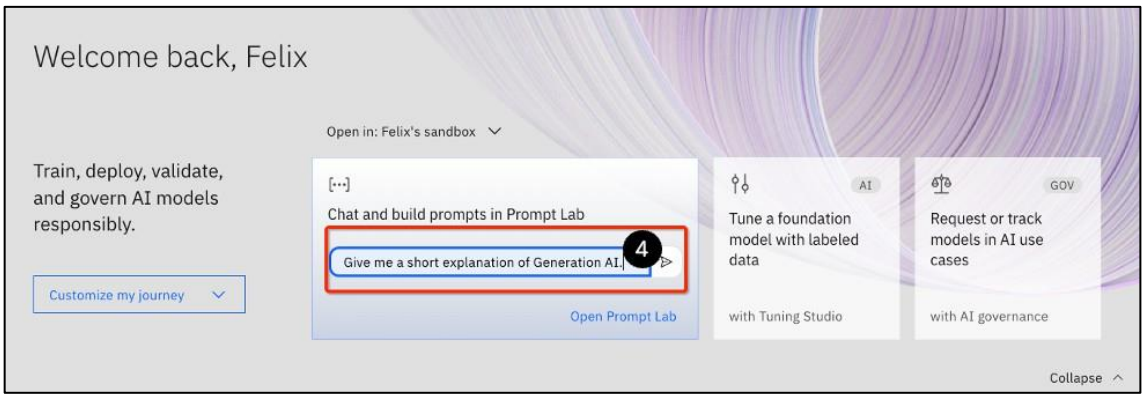
3. Lorsque vous utilisez un compte TechZone, vous devez disposer d'un projet de bac à sable. Si vous n'utilisez pas le projet de bac à sable, cliquez sur le menu déroulant et sélectionnez le projet de bac à sable. S'il répertorie déjà le projet de bac à sable, passez à l'étape 4.



© 2024 Société IBM

4. Entrez le texte suivant dans le champ de saisie Chat, puis appuyez sur Entrée.





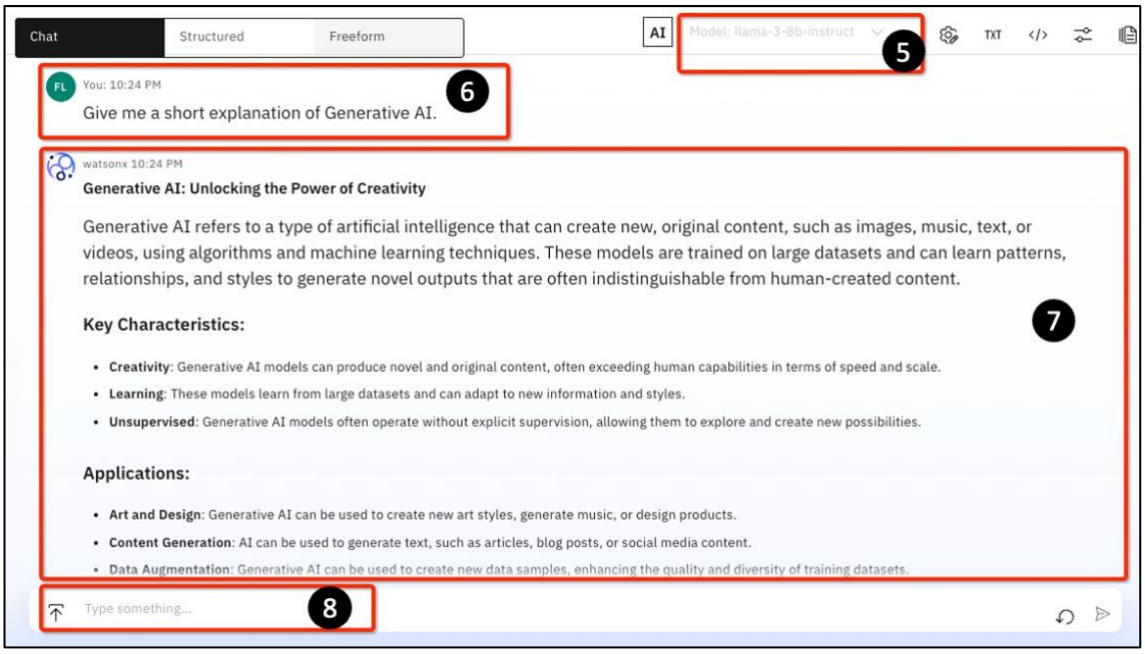
5. La page Chat s'ouvre. Le modèle utilisé est llama-3-8b-instruct. Notez que le nom est grisé (voir capture d'écran ci-dessous). Une fois que vous avez démarré une session de chat, le modèle ainsi que les paramètres d'inférence sont verrouillés et ne peuvent pas être modifiés (nous y reviendrons plus tard).

6. Le texte de l'invite de saisie s'affiche sur la page.

7. La fin de l'achèvement peut prendre quelques secondes (partiellement illustré ci-dessous). La valeur maximale des jetons est élevée dans une session de chat, et le volume de texte généré peut être assez important.

8. Vous pouvez entrer une autre invite et avoir une « conversation » avec le LLM.

© 2024 Société IBM



Lorsque vous commencez à utiliser Chat de cette façon, vous ne verrez pas les exemples et vous ne pourrez pas choisir le modèle que vous souhaitez utiliser. À un niveau élevé, un chat est avec état. Le LLM doit se souvenir du contexte de la conversation, de sorte que le modèle (ainsi que les paramètres d'inférence) doit être conservé.

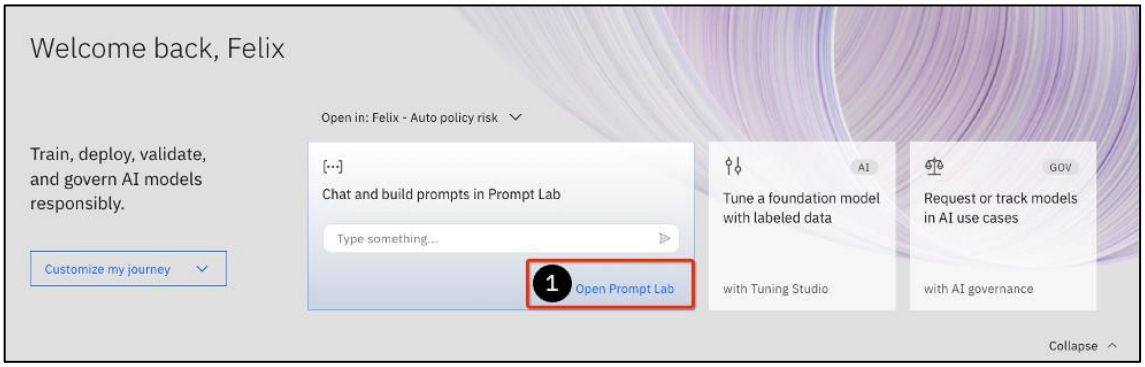
Prenons l'exemple d'un client qui appelle un centre d'assistance. Ce client a besoin d'être servi par le même agent et de ne pas être transféré à un autre agent à chaque fois qu'il dit quelque chose, car le nouvel agent n'aurait pas le contexte de la conversation précédente. Dans une section ultérieure, vous examinerez le code utilisé dans un chat et le raisonnement deviendra plus clair.

Dans la section suivante, vous accéderez à Chat via le Prompt Lab.

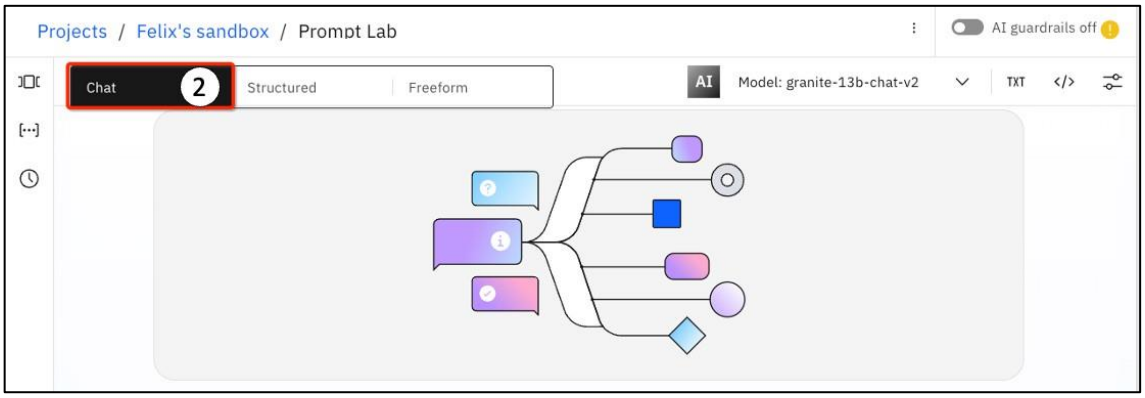
© 2024 Société IBM

4.2 Accès à la conversation dans le laboratoire d'invite

1. Ouvrez une nouvelle session watsonx.ai et cliquez sur Ouvrir l'atelier d'invite sur la première vignette.

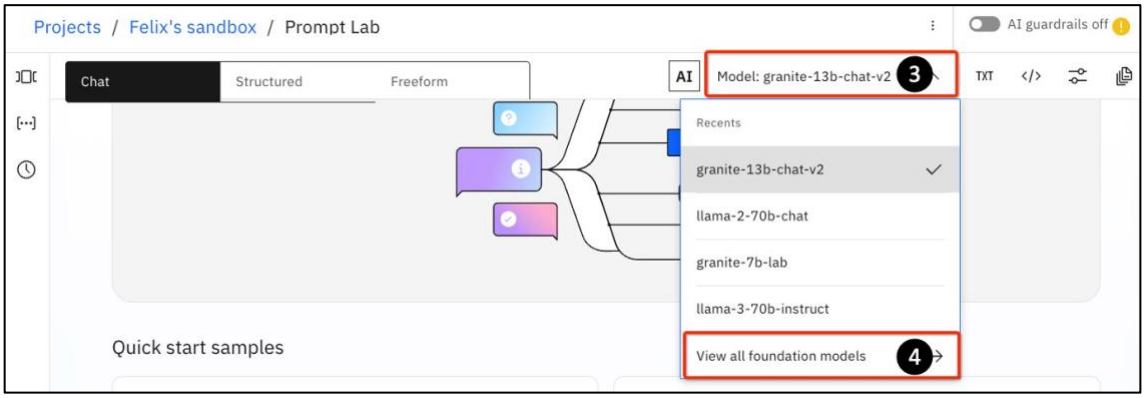


2. Si vous êtes connecté à une nouvelle session watsonx.ai, watsonx.ai s'ouvre en mode Chat. Si ce n'est pas le cas, vous pouvez cliquer sur l' onglet Chat.



3. Notez que le modèle présenté ici est granite-13b-chat-v2. Vous pouvez en voir un autre ; watsonx.ai montrez toujours le dernier modèle que vous avez utilisé.

4. Cliquez sur dans la liste déroulante, puis sélectionnez Afficher tous les modèles de fondation.



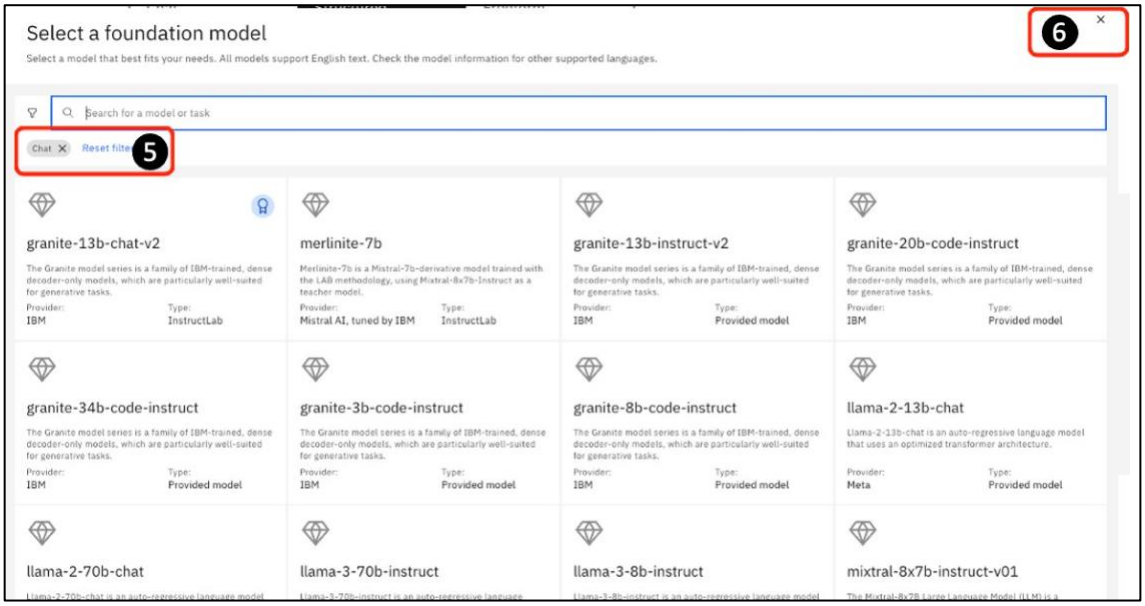
© 2024 Société IBM

5. Notez que seul un sous-ensemble de tous les LLM watsonx.ai apparaît dans cette liste. Par exemple, les modèles codellama-34b-instruct-hf et mixtral-8x7b-instruct-v01 ne sont pas ici.

   Pourquoi? Parce que c'est le filtre de chat est activé. Sur la page Sélectionner un modèle de base, ce filtre watsonx.ai est appliqué pour afficher uniquement les modèles qui sont balisés pour traiter la tâche de conversation.

   Au fur et à mesure que des modèles seront ajoutés et supprimés de la liste watsonx.ai, il se peut que vous voyiez une liste différente. Cet atelier commence avec granite-13b-chat-v2. Il peut être utile d'essayer différents modèles pour voir comment différents modèles se comportent pour la tâche de chat particulière que vous travaillez.

6. Pour l'instant, il suffit de fermer la page Sélectionner un modèle de base.

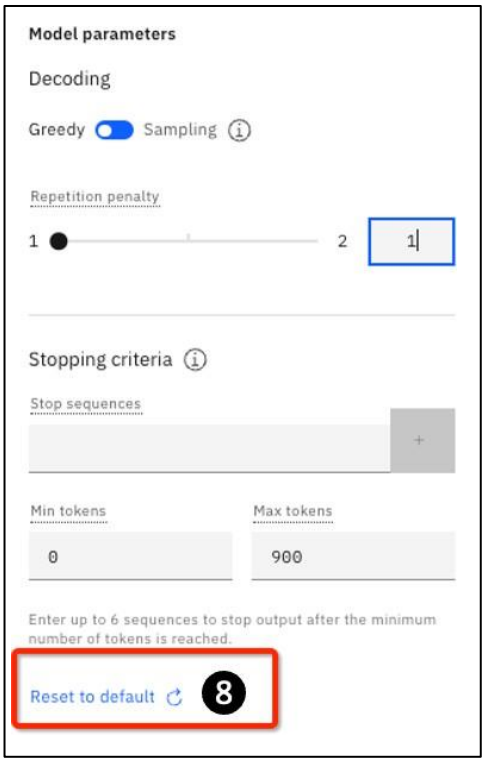


7. Cliquez sur le curseur Paramètres du modèle (l'icône de glissement ressemble à ceci : ⚟).



8. En fonction de ce que vous avez pu faire précédemment, vous pouvez avoir des valeurs différentes, cliquez sur Réinitialiser par défaut. Notez que si vous n'avez jamais modifié de valeurs, vous ne verrez pas le bouton Réinitialiser par défaut.

© 2024 Société IBM



9. Les valeurs par défaut sont les suivantes :

    a. Décodage : Gourmand. Watsonx.ai renvoie l'achèvement le plus probable.

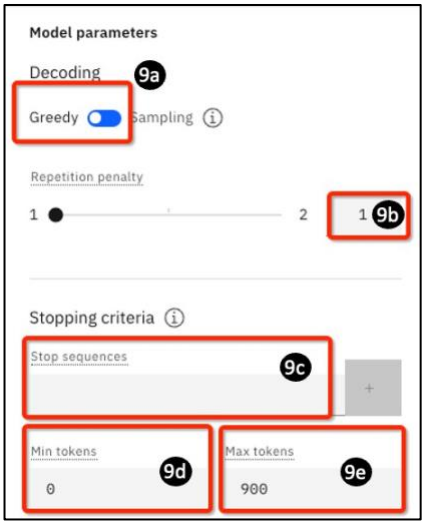
    b. Pénalité de répétition : 1. Parfois, un grand modèle de langage (LLM) peut renvoyer les mêmes informations à plusieurs reprises, ce qui peut consommer des jetons (et générer des coûts) inutilement. Un réglage de 1 permet la répétition. Vous pouvez le définir plus haut si vous souhaitez réduire les chances que le modèle génère le même texte.

    c. Séquences d'arrêt : aucune définie

    d. Nombre minimum de jetons : 0

    e. Nombre maximum de jetons : 900

© 2024 Société IBM



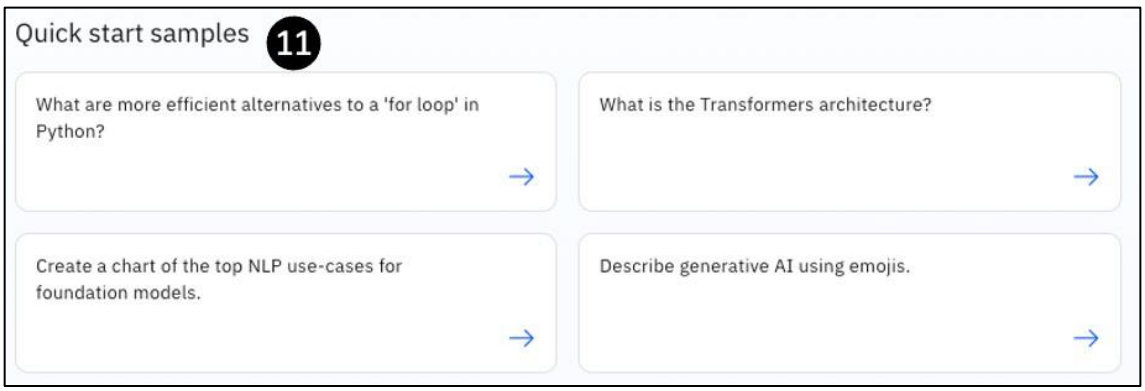
Vous pouvez changer le décodage de Gourmand à Échantillonnage. Si vous le faites, vous verrez des paramètres d'inférence supplémentaires que vous pouvez modifier, tels que les critères Température, Top P, Top K, Valeur de départ aléatoire et Arrêt. Ceux-ci sont couverts en détail dans ce laboratoire pratique de niveau 3 et ne seront pas abordés plus en détail ici.

10. En fonction de ce que vous avez fait lors des sessions de watsonx.ai précédentes, vous avez peut-être désactivé les garde-fous de l'IA. Si c'est le cas, réglez l'interrupteur des garde-fous IA sur activé (lorsque les garde-fous sont désactivés, vous verrez une icône de point d'exclamation jaune à côté de l'interrupteur

).



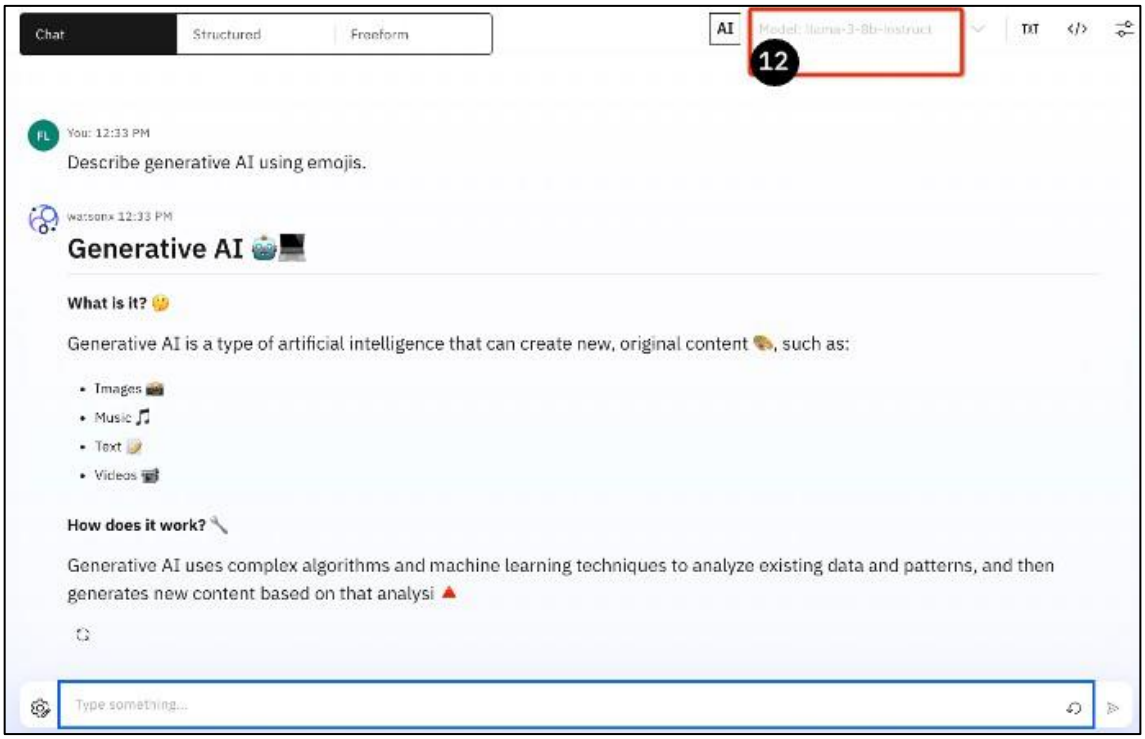
11. Le chat fournit un ensemble d'exemples (la liste peut changer) :



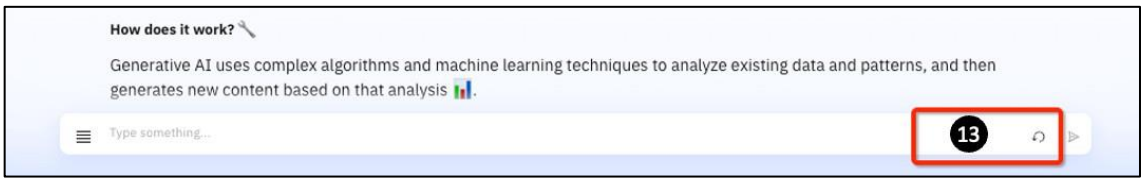
Ceux-ci sont très utiles pour découvrir comment les LLM peuvent fournir un excellent résultat à la fois dans le contenu et le format. Vous en essayerez quelques-uns ensuite.

© 2024 Société IBM

12. Sélectionnez l' exemple Décrire l'IA générative à l'aide d'emojis. Vous verrez le résultat suivant (partiellement affiché). Notez que lorsque vous sélectionnez l'un des 4 échantillons, watsonx.ai sélectionne automatiquement le LLM à utiliser. Pour cet exemple, il s'agit du modèle lama-3-8b-instruct.



13. Effacez le chat en cliquant sur Effacer le chat.



14. Vous reviendrez à la liste des exemples présentés à l'étape 11.

Résumé de la section

Dans cette section, vous avez vu comment accéder à Chat dans watsonx.ai, les LLM que watsonx.ai a balisés pour le cas d' utilisation de réponse aux questions et les paramètres d'inférence du modèle.

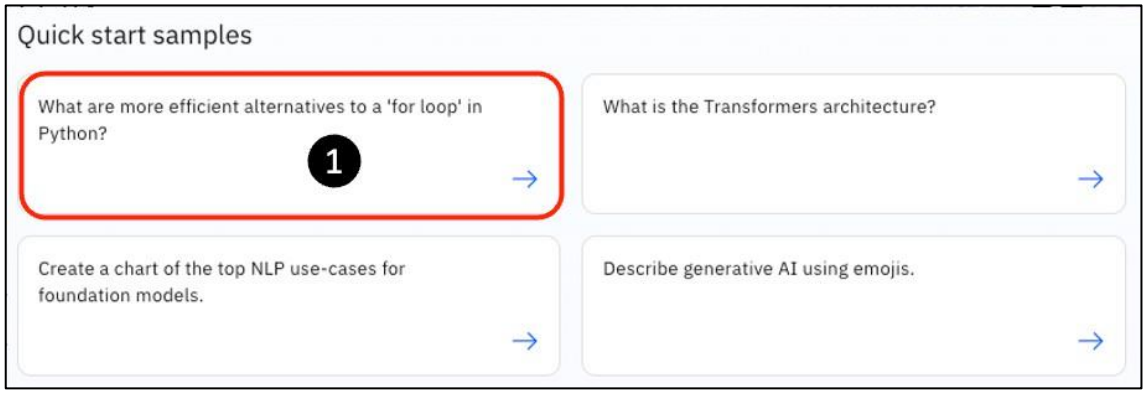
Vous pouvez tester chacun des 4 exemples de chat fournis. Après l'achèvement initial, vous pouvez poursuivre une discussion avec le LLM à partir de là.

© 2024 Société IBM

4.3 Exemple de session de chat

Dans cette section, vous allez voir différents exemples de chat fournis par watsonx.ai. L'une des informations les plus utiles est la façon de fournir des instructions pour que le LLM puisse sortir dans le format que vous souhaitez.

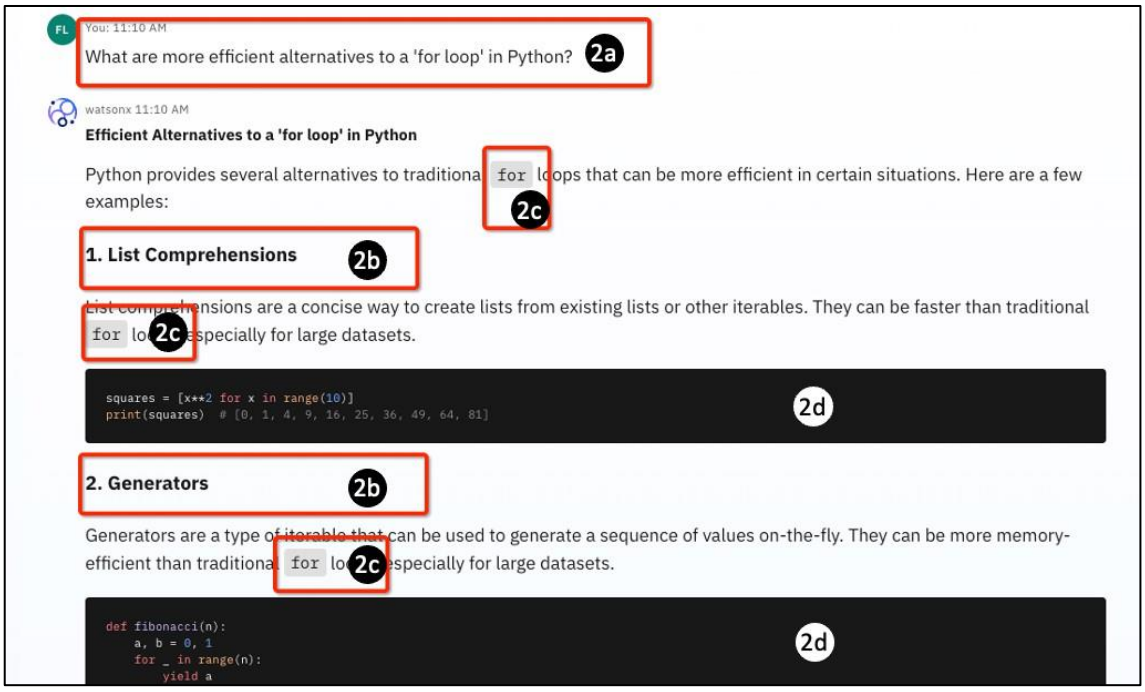
5. Dans la liste des exemples de chat, cliquez sur le premier : Quelles sont les alternatives les plus efficaces à une boucle 'for' en Python ?



6. Vous verrez le résultat suivant (seulement partiellement capturé ici). La réalisation se fait dans un format bien structuré :

    a. L'invite de saisie est mise en surbrillance en haut dans une boîte grise.
    b. Différentes alternatives sont numérotées, ce qui les rend plus faciles à repérer
    c. Divers éléments Python sont surlignés en gris.
    d. Les extraits de code sont fournis au format Markdown

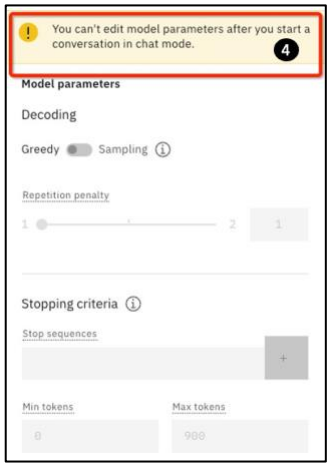
© 2024 Société IBM



3. Le modèle llama-3-8b-instruct a été automatiquement choisi pour cet exemple d'invite et il a renvoyé 4 alternatives à une boucle « for » Python :

    a. Compréhension de la liste
    b. Générateurs
    c. Fonctions de mappage et de filtrage
    d. Fonctions itertools

4. IBM watsonx.ai peut modifier certains paramètres d'inférence par défaut au début de votre session de conversation. Une fois que vous avez démarré une conversation en mode Chat, vous ne pouvez plus modifier des paramètres tels que les méthodes de décodage ou des éléments tels que les jetons Max.

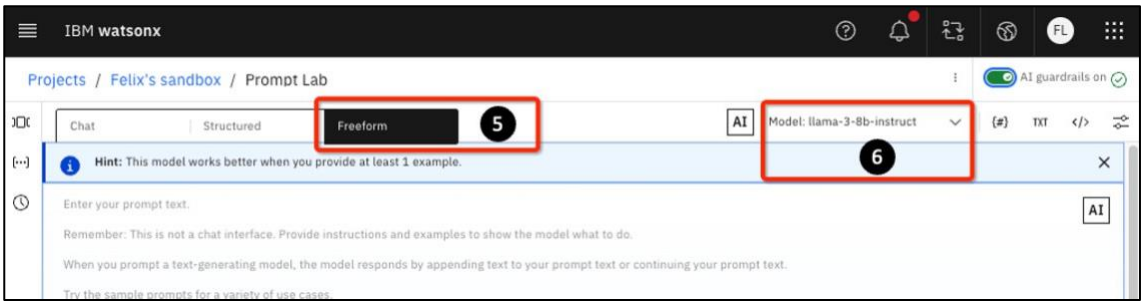


© 2024 Société IBM

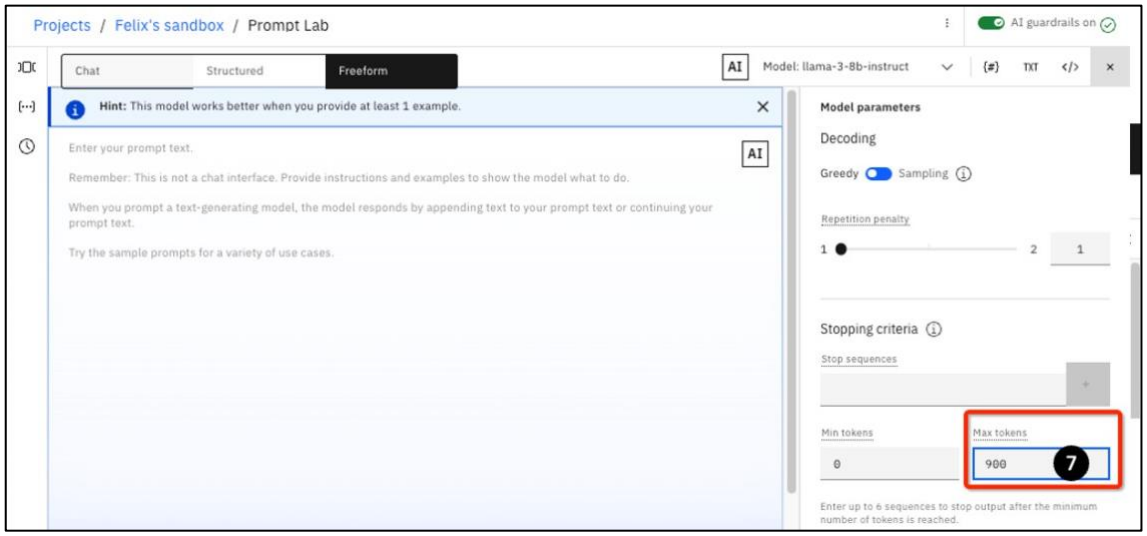
Vous allez maintenant essayer la même invite en mode structuré. N'effacez pas le texte généré ou l'invite. Vous y reviendrez.

5. Dans la session Prompt Lab en cours, cliquez sur l' onglet Forme libre.

6. Sélectionnez le modèle lama-3-8b-instruct à utiliser (si ce n'est pas déjà fait, c'est pour que vous puissiez le comparer à la sortie du chat).



7. Assurez-vous que Max tokens est défini sur 900 dans les paramètres du modèle (vous pouvez y accéder comme vous l'avez fait à l'étape 7 de la section 5.2).



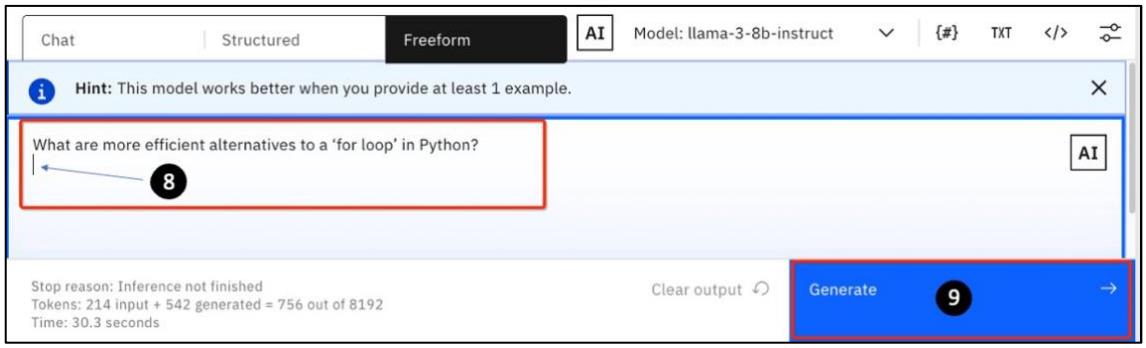
8. Entrez la même invite que dans l' exemple de chat. Assurez-vous d'inclure le retour chariot (représenté par la ligne vide supplémentaire sous ce que vous avez tapé et par la position du curseur dans la capture d'écran).

```
Quelles sont les alternatives les plus efficaces à une boucle « for » en
Python ?
```

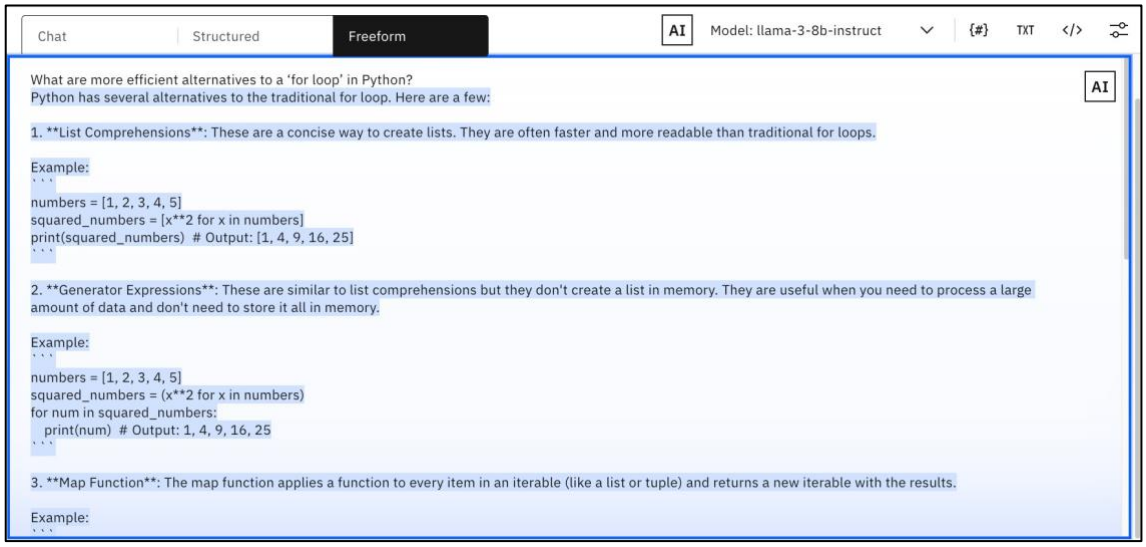
Exercice bonus : Que va générer le modèle si vous n'avez pas le retour chariot ?

© 2024 Société IBM

9. Cliquez sur Générer.



Vous obtiendrez cette complétion (partiellement illustrée ci-dessous) :



10. Les sessions structurées et les sessions de chat utilisent le modèle lama-3-8b-instruct. Il y a des similitudes entre les 2 complétions : les deux fournissent une sortie numérotée, et les alternatives et les descriptions sont similaires. Cependant, notez ici que Chat et Freeform proposent des alternatives différentes pour la boucle « for » :

Bavarder	Freeform
• Compréhension de la liste • Générateurs • Fonctions de mappage et de filtrage • Fonctions itertools	• Compréhension de la liste • Expressions génératrices • Fonction de carte • Fonction de filtre • Fonction Zip • Fonction enumerate

La complétion du chat est plus structurée et plus facile à lire et à extraire des informations. Notez également que les exemples de code sont au format de bloc

© 2024 Société IBM

Markdown.

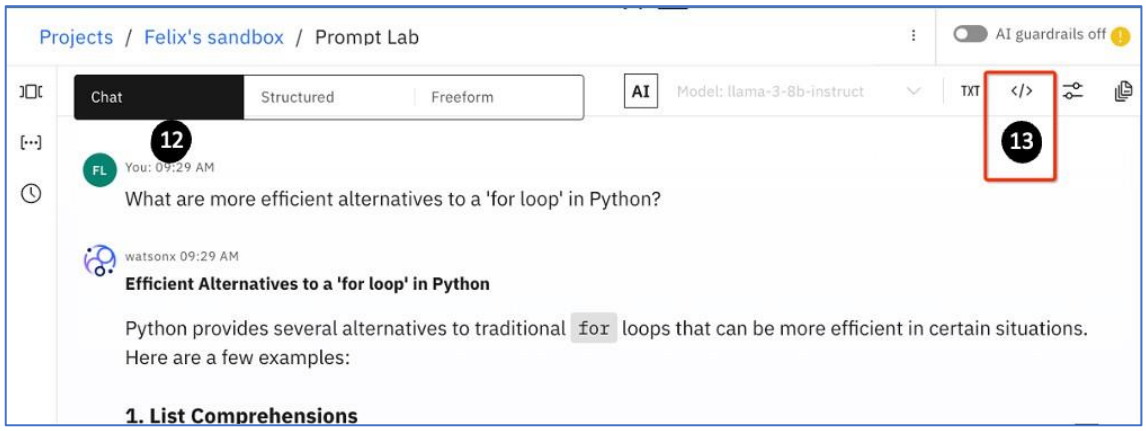
© 2024 Société IBM

11. Freeform et Chat ont tous deux utilisé le même modèle ainsi que les mêmes paramètres d'inférence. La différence réside dans la façon dont Chat a augmenté l'invite pour fournir une sortie claire et formatée.

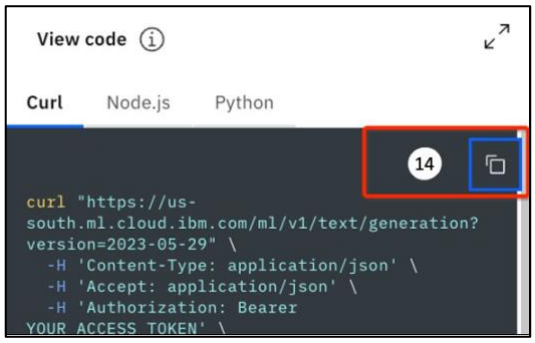
    Ensuite, vous allez ajouter le même texte augmenté à la session d'invite Freeform en tant qu'instructions et observer son fonctionnement.

12. Cliquez sur Chat pour revenir à l'onglet Chat. Vous devriez toujours y avoir la sortie de l'invite d'échantillon. Si ce n'est pas le cas, vous pouvez réexécuter l'étape 1 pour générer à nouveau l'achèvement.

13. Cliquez sur l'icône Afficher le code (</>) sur la droite pour afficher ce que watsonx.ai ajoute à l'invite en mode Chat.



14. IBM watsonx.ai affiche le code sous-jacent pour chaque interaction LLM. Si vous utilisez du code Python, si vous créez un bloc-notes Jupyter ou si vous exécutez simplement à partir d'une ligne de commande, vous pouvez copier l'intégralité de cet extrait de code en cliquant sur l'icône de copie ( ), puis en collant la sortie dans un fichier.



    Vous pouvez également modifier cet extrait en ajoutant/mettant à jour les instructions.

15. Pour cet atelier, cliquez sur l'icône TXT pour obtenir une version texte de cette sortie.

© 2024 Société IBM



Vous pouvez copier le texte avec l'icône de copie (la même qu'à l'étape 15).

16. Le texte ci-dessous est l'ensemble des instructions ajoutées par watsonx.ai pour la session de chat.

```
<|begin_of_text|><|start_header_id|>système<|end_header_id|>

Vous répondez toujours aux questions avec la mise en forme Markdown à l'aide de la syntaxe GitHub. Le formatage Markdown que vous prenez en charge : en-têtes, gras, italique, liens, tableaux, listes, blocs de code et guillemets. Vous devez omettre de répondre aux questions avec markdown.

Toutes les balises HTML doivent être enveloppées entre guillemets, par exemple "'<html>'. Vous serez pénalisé pour ne pas avoir rendu le code entre guillemets.

Lorsque vous renvoyez des blocs de code, spécifiez la langue.

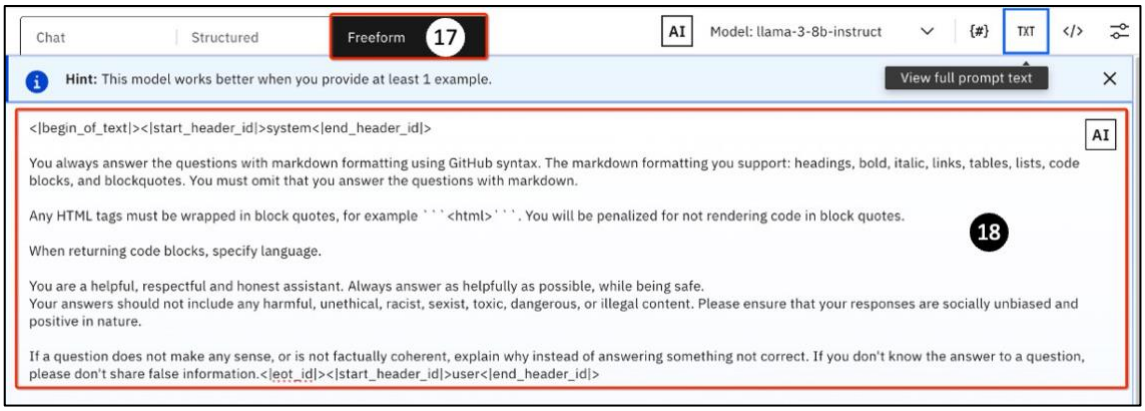
Vous êtes un assistant serviable, respectueux et honnête. Répondez toujours de la manière la plus utile possible, tout en étant en sécurité. Vos réponses ne doivent pas inclure de contenu nuisible, contraire à l'éthique, raciste, sexiste, toxique, dangereux ou illégal. Veuillez vous assurer que vos réponses sont socialement impartiales et de nature positive.

Si une question n'a aucun sens, ou n'est pas cohérente sur le plan factuel, expliquez pourquoi au lieu de répondre à quelque chose qui n'est pas correct. Si vous ne connaissez pas la réponse à une question, ne partagez pas de fausses
```

17. Revenez maintenant à l' onglet Forme libre.

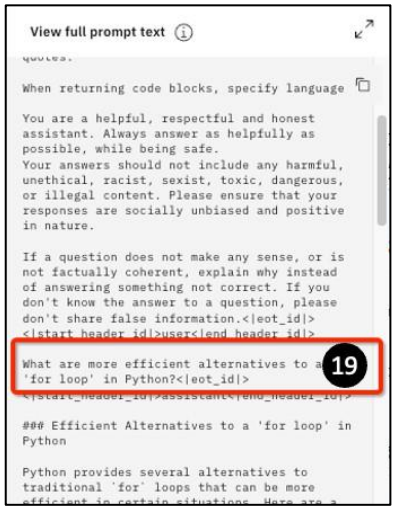
18. Ajoutez le texte de l'étape 16 en haut du champ de saisie. Cela devrait ressembler à ceci :

© 2024 Société IBM



19. Revenez à l' onglet Chat et ouvrez à nouveau le curseur TXT. Cette fois, copiez le texte associé à cette invite. Le texte du chat est le suivant :

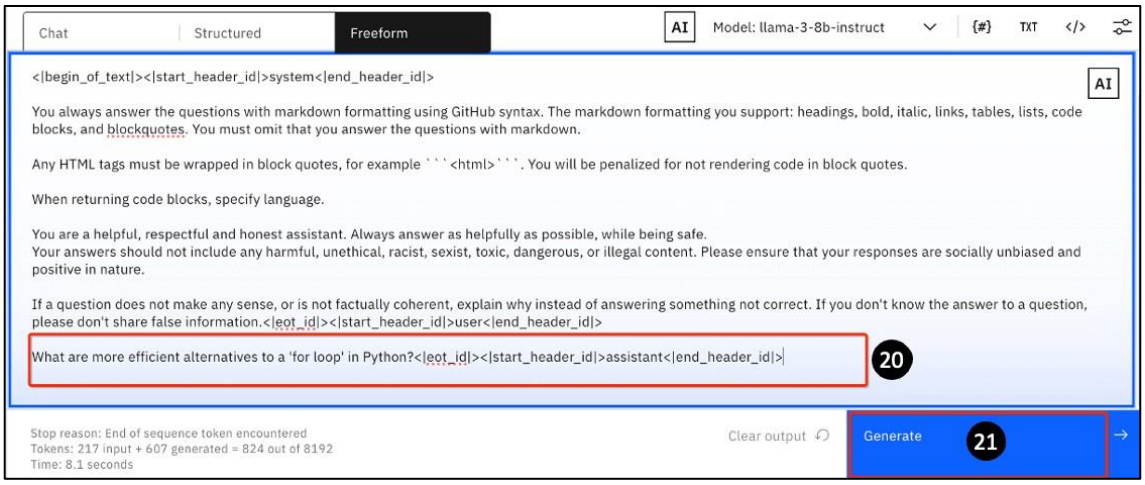
```
Quelles sont les alternatives les plus efficaces à une boucle « for » en Python ?<|eot_id|>
```



20. Revenez maintenant à l' onglet Forme libre. Entrez deux retours chariot pour séparer les lignes. Ajoutez ensuite le texte que vous venez de copier à l'étape 19. Vous devriez voir la capture d'écran ci-dessous (avec le texte ajouté mis en évidence par une boîte rouge).

21. Cliquez sur Générer.

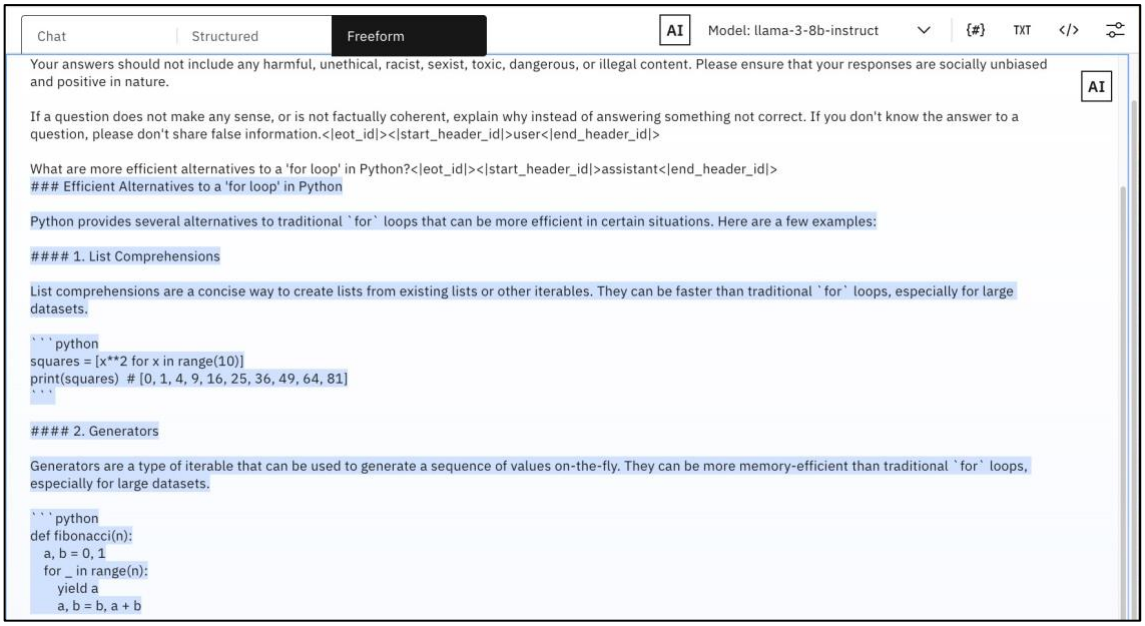
© 2024 Société IBM



22. Notez que vos instructions incluent les points suivants :

- Le format Markdown est spécifié, créant ainsi un cadre de base du format de sortie
- Des éléments Markdown spécifiques sont spécifiés, limitant la façon dont le LLM peut générer l'achèvement
- Le ton (utile, respectueux et honnête) et la manière de terminer (sûr, non nuisible, contraire à l'éthique, etc. dans la sortie) sont spécifiés
- Demandez des éclaircissements si l'invite de saisie n'est pas claire
- N'inventez pas les choses si le LLM ne sait pas comment réagir.

Voici la saisie semi-automatique générée (partiellement illustrée) :



Cette fois-ci, le mode Freeform affiche les mêmes 4 options :

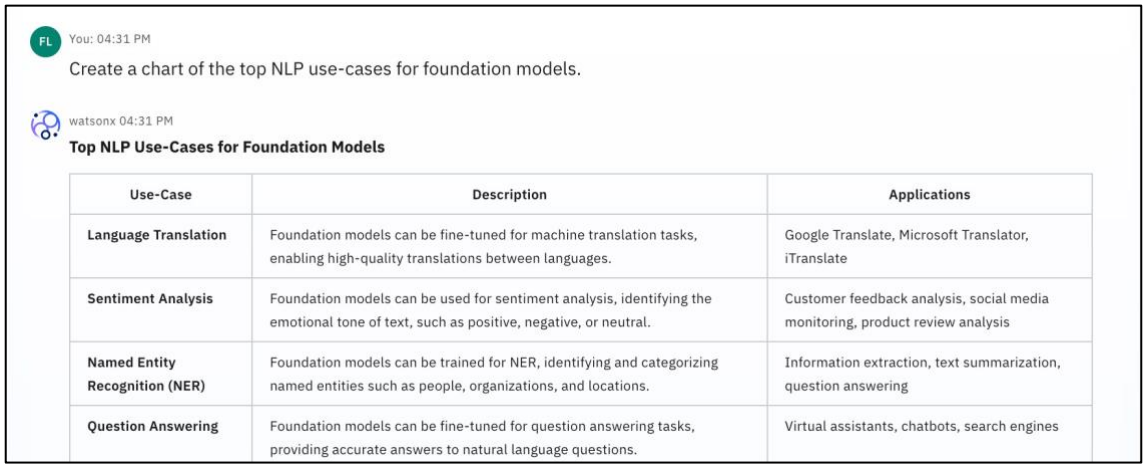
- Compréhension de la liste
- Générateurs
- Fonctions de mappage et de filtrage
- Fonctions itertools

Vous remarquerez peut-être quelques différences (très) mineures, mais avec les mêmes instructions saisies, vous obtenez les mêmes alternatives et exemples dans le mode Freeform que dans le mode Chat.

23. Il est maintenant temps d'essayer différents exemples de Chat. Tout d'abord, retournez dans Chat et cliquez sur l' icône Effacer le chat (↺) sur le côté droit de la zone de texte de saisie pour effacer toutes les entrées et revenir à la liste des échantillons.



24. Cliquez sur Créer un graphique des principaux cas d'utilisation du NLP pour les modèles de base. Voici le résultat (partiel) :



A noter plusieurs points :

- Cet exemple continue d'utiliser le modèle llama-3-8b-instruct. Si vous vérifiez les paramètres, il utilise également Max tokens 900.
- L'invite spécifiait Créez un graphique, et le LLM a généré un tableau très soigné et clair avec des en-têtes appropriés.

21. Il est à nouveau utile d'examiner quel code watsonx.ai a ajouté pour que le LLM réponde de cette manière. Cliquez sur l'icône Afficher le code (</>) et regardez le code (ou copiez-le). Vous verrez ce qui suit :

© 2024 Société IBM

> Vous répondez toujours aux questions avec un format Markdown. Le markdown Mise en forme que vous prenez en charge : en-têtes, gras, italique, liens, tableaux, listes, blocs de code et guillemets. Vous devez omettre de répondre aux questions avec markdown.
>
> Toutes les balises HTML doivent être enveloppées entre guillemets, par exemple "'<html>'. Vous serez pénalisé pour ne pas avoir rendu le code entre guillemets.
>
> Lorsque vous renvoyez des blocs de code, spécifiez la langue.
>
> Vous êtes un assistant serviable, respectueux et honnête. Répondez toujours de la manière la plus utile possible, tout en étant en sécurité.
>
> Vos réponses ne doivent pas inclure de contenu nuisible, contraire à l'éthique, raciste, sexiste, toxique, dangereux ou illégal. Veuillez vous assurer que vos réponses sont socialement impartiales et de nature positive.
>
> Si une question n'a aucun sens, ou n'est pas cohérente sur le plan factuel, expliquez pourquoi au lieu de répondre à quelque chose qui n'est pas correct. Si vous ne connaissez pas la réponse à une question, veuillez ne pas partager de fausses informations.

Il s'agit du même texte que celui de l'étape 16. Si vous essayez les 2 autres exemples d'invites et que vous regardez le code, ils seront tous identiques.

Le problème, c'est que cet ensemble d'instructions, ainsi que l 'instruction lama-3-8b, forment une combinaison puissante pour créer une sortie structurée à l'aide de Markdown.

© 2024 Société IBM

Résumé de la section

- Le watsonx.ai Chat prend en charge le cas d'utilisation du chat interactif. Notez que watsonx.ai sélectionne automatiquement un sous-ensemble de modèles disponibles pour cette tâche. Les modèles tels que mixtral-8x7b-instruct-v01-q sont filtrés.

- Le chat montre certaines capacités fondamentales pour les LLM telles que llama-3-8b-instruct pour soutenir les sessions interactives avec les clients.

- En utilisant un LLM (tel que llama-3-8b-instruct) qui comprend Markdown, il est assez simple de fournir un ensemble standard d'instructions pour augmenter une invite d'entrée afin de générer une sortie hautement formatée.

- Vous pouvez copier les instructions de l' exemple Chat et les utiliser dans le formulaire libre ou
  Mode structuré pour le personnaliser et essayer différents modèles ou paramètres de modèle.

- Vous pouvez configurer une session de chat avant de démarrer un chat qui inclut le choix de LLM et divers paramètres d'inférence. Une fois que vous avez démarré la session de chat, vous ne pouvez pas passer à un autre modèle ou modifier les paramètres.

- Notez qu'en mode Chat, la valeur des jetons Max est définie sur une valeur élevée (peut aller jusqu'à 900). Bien que cela puisse être souhaitable dans la production réelle, les clients (en particulier les développeurs) doivent être conscients que cela peut être coûteux.

- Dans cette section, vous avez utilisé les instructions de chat avec le mode Freeform. Vous pouvez également essayer de copier les instructions en mode Structuré. Cependant, il ne fonctionnera pas aussi bien car le mode structuré inclut son propre texte d'instruction et sa propre structure sous-jacente, et il interférera avec les instructions de chat.

© 2024 Société IBM

4.4 Différents LLM pris en charge dans watsonx.ai Chat

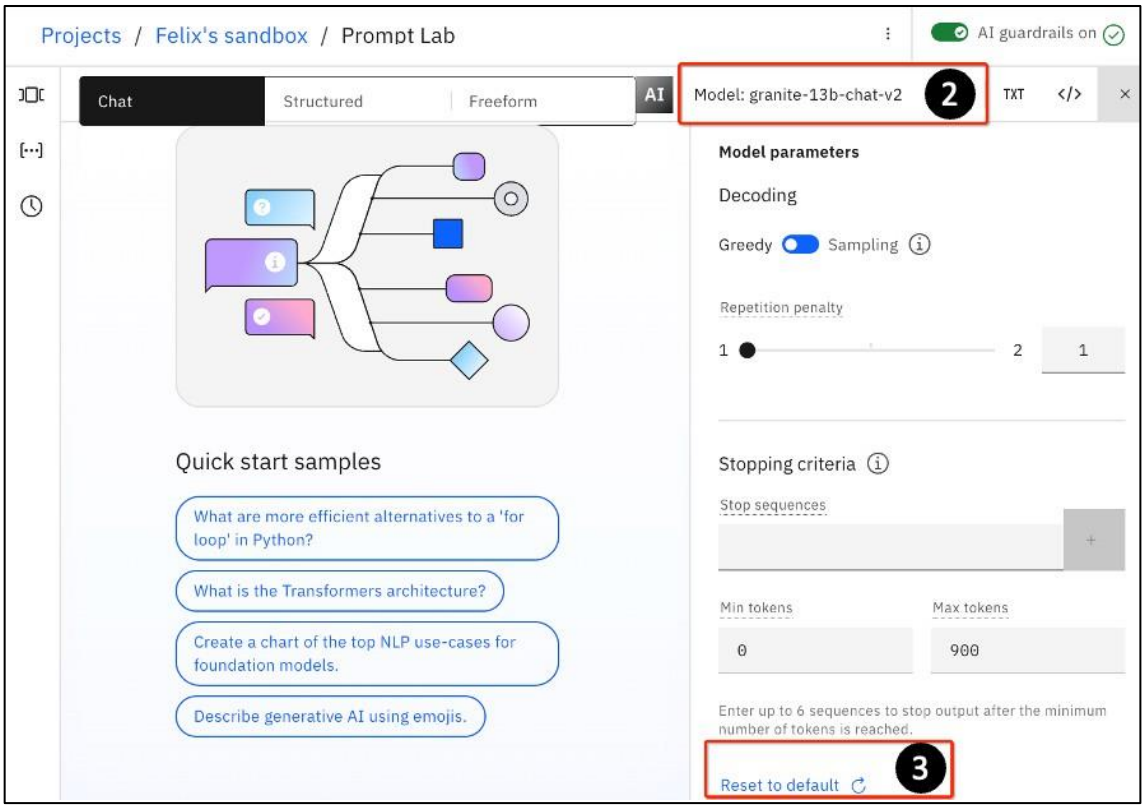
Dans cette section, vous examinerez différents modèles et comment watsonx.ai fournit des instructions supplémentaires au LLM.

1. Dans l' onglet Chat, cliquez sur l' icône Effacer le chat (↺) sur le côté droit de la zone de texte de saisie pour effacer toutes les entrées et revenir à la liste des échantillons.



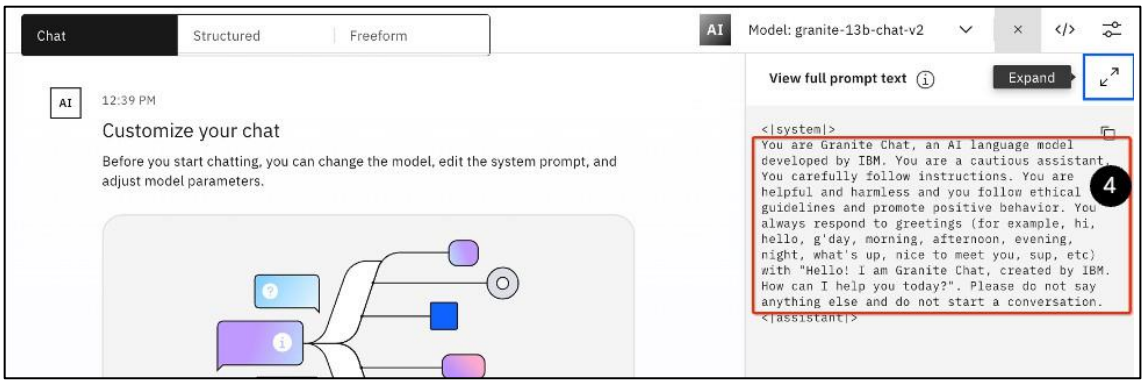
2. Assurez-vous d'utiliser le modèle granite-13b-chat-v2.

3. Ouvrez le curseur Paramètres du modèle et cliquez sur Réinitialiser par défaut (cela garantit que Max tokens est réinitialisé à 900). Si vous ne voyez pas ce lien, cela signifie que vous utilisez déjà les paramètres de watsonx.ai par défaut.



© 2024 Société IBM

4. Cliquez sur TXT pour voir quelles instructions watsonx.ai ajoute aux invites auxquelles il est soumis
granite-13b-chat-v2 et copiez le texte.



Voici les instructions (formatées pour faciliter la lecture).

<|système|>
Vous êtes Granite Chat, un modèle de langage d'IA développé par IBM. Vous êtes un assistant prudent. Vous suivez attentivement les instructions. Vous êtes serviable et inoffensif, vous suivez les directives éthiques et promouvez un comportement positif. Vous répondez toujours aux salutations (par exemple, bonjour, bonjour, bonjour, matin, après-midi, soir, soir, quoi de neuf, ravi de vous rencontrer, souper, etc.) par "Bonjour ! Je suis Granite Chat, créé par IBM. Comment puis-je vous aider aujourd'hui ? S'il vous plaît, ne dites rien d'autre et n'entamez pas de conversation.

Il y a des similitudes et des différences entre cette instruction et ce qui a été fourni lorsque vous avez généré une complétion à l'aide du modèle llama-3-8b-instruct dans la Section 5.3, étape 16.

a. Similitudes
   i. Les deux modèles ont reçu l'instruction d'être « utiles et inoffensifs »
   ii. Les deux modèles ont été instruits d'être « éthiques » (pour être précis, l'instruction pour l 'invite lama-3-8b-instruct est qu'elle « ne devrait pas inclure de substances nocives, contraires à l'éthique... contenu".

b. Différences
   i. Il n'y a pas d'instruction pour utiliser markdown pour le modèle granite-13b-chat-v2. Cela ne signifie PAS que granite-13b-chat-v2 ne peut pas comprendre ou produire une sortie Markdown (même si différents modèles fourniront visuellement une sortie Markdown différente). Les 4 exemples énumérés sur la page de discussion étaient destinés à fournir des exemples de ce que les LLM correctement instruits peuvent faire, de sorte

© 2024 Société IBM

que leurs instructions étaient plus spécifiques.

© 2024 Société IBM

ii. Il existe des instructions plus explicites pour que le modèle lama-3-8b-instruct n'inclue pas de « contenu sexiste, toxique, dangereux ou illégal ». Il s'agit probablement d'une précaution car, contrairement aux modèles en granit, IBM ne sait pas comment
Les modèles Llama-3 ont été formés.

Notez que cette différence peut disparaître et que watsonx.ai pouvez unifier la partie ajoutée de l'invite de saisie au LLM

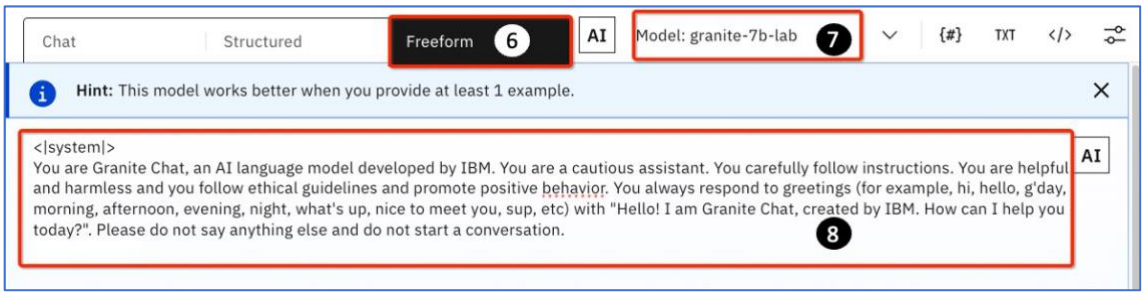
5. Il peut être instructif d'examiner comment différents modèles généreraient un achèvement. Vous avez déjà vu comment llama-3-8b-instruct se comporte pour le Quelles sont les alternatives les plus efficaces à une boucle 'for' en Python ? prompt. Vous allez maintenant voir ce que fera le modèle granite-7b-lab.

   Remarque : Vous ne pouvez pas simplement présélectionner le modèle granite-7b-lab, puis cliquer sur Quelles sont les alternatives les plus efficaces à une boucle « for » en Python ? exemple sur le Chat, car watsonx.ai passera automatiquement au modèle llama-2-70b-instruct pour cet exemple. Au lieu de cela, utilisez l' onglet Forme libre comme dans la Section 5.3 et les instructions ajoutées obtenues à l'étape 4 ci-dessus.

6. Sélectionnez l' onglet Forme libre.

7. Assurez-vous que vous utilisez le modèle granite-7b-lab (et que Max tokens est défini sur 900).

8. Collez le texte que vous avez copié à partir de la zone grise à l'étape 4 ici dans le champ de saisie Forme libre.



9. Lorsque vous entrez une invite à l'aide du modèle granite, vous utilisez une balise <|user|>, puis vous signifiez la fin de votre invite à l'aide de la balise <|assistant|>.

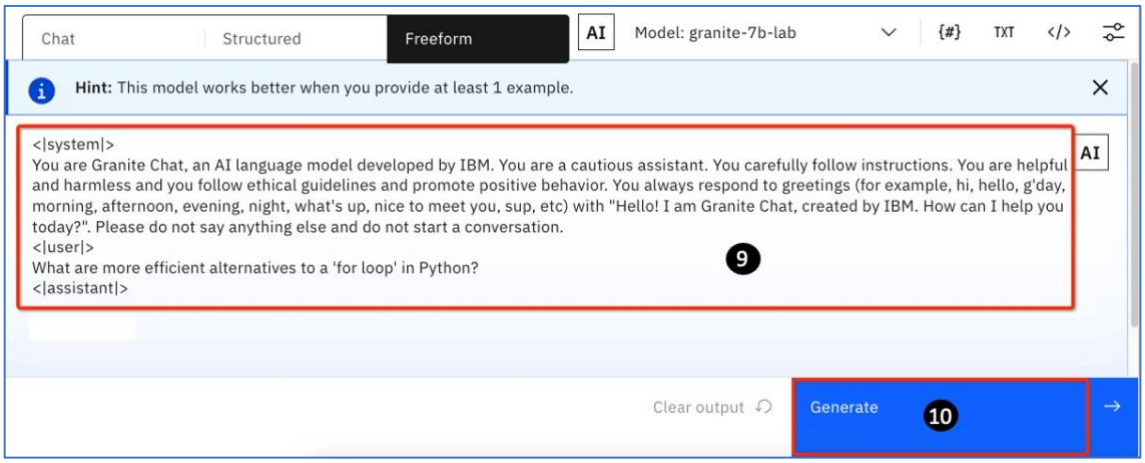
   Ajoutez le texte suivant à ce que vous avez déjà saisi ci-dessus.

© 2024 Société IBM

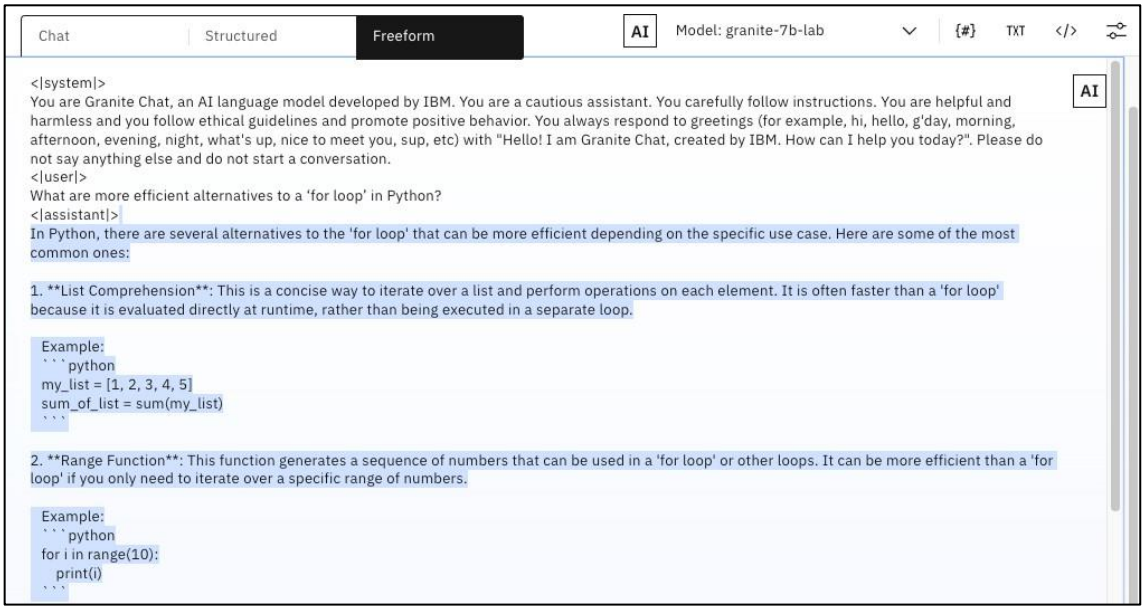
<|utilisateur|>
Quelles sont les alternatives les plus efficaces à une boucle « for » en Python ?
<|assistant|>

© 2024 Société IBM

10. Cliquez sur Générer.



Votre sortie doit ressembler à ce qui suit (partiellement illustré) :



Voici les alternatives générées par granite-7b-lab :

a. Compréhension de liste
b. Fonction de portée
c. Fonction de carte
d. Fonction de filtrage
e. Compréhension de liste avec If

Pour rappel, voici la liste de llama-3-8b-instruct :

a. Compréhension de la liste
b. Expressions génératrices

© 2024 Société IBM

c. Fonction de carte
d. Itertools

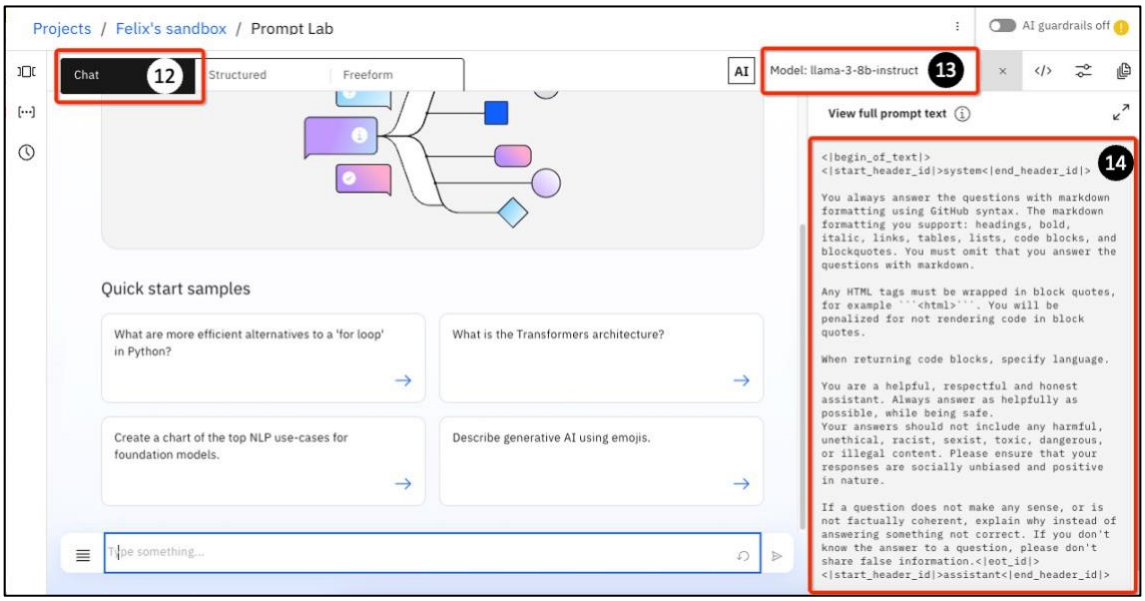
Deux d'entre eux sont courants : la compréhension de liste et la fonction Map. Ce n'est pas le but de ce laboratoire d'évaluer les alternatives. Bien que la liste générée par llama-3-8b-instruct soit plus courte, les options sont probablement plus connues et utilisées. Notez qu'avec le
granite-7b-lab , vous n'avez pas besoin de lui demander explicitement d'utiliser le balisage markdown. Il sait automatiquement qu'il doit l'utiliser avec la sortie de code.

11. Vous allez maintenant utiliser les instructions que watsonx.ai fournit pour le lama-3-8b-instruct
dans une session de chat avec le modèle Granite-7B-Lab et voyez s'il y a une différence.

12. Sélectionnez l'onglet Chat

13. Assurez-vous que vous utilisez le modèle llama-3-8b-instruct.

Cliquez sur l' icône TXT et vous verrez ce qui suit (seulement partiellement affiché) :



Copiez une partie du texte (illustré dans l'encadré gris ci-dessous) :

© 2024 Société IBM

Vous répondez toujours aux questions avec la mise en forme Markdown à l'aide de la syntaxe GitHub. Le formatage Markdown que vous prenez en charge : en-têtes, gras, italique, liens, tableaux, listes, blocs de code et guillemets. Vous devez omettre de répondre aux questions avec markdown.

Toutes les balises HTML doivent être enveloppées entre guillemets, par exemple "'<html>'. Vous serez pénalisé pour ne pas avoir rendu le code entre guillemets.

Lorsque vous renvoyez des blocs de code, spécifiez la langue.

Vous êtes un assistant serviable, respectueux et honnête. Répondez toujours de la manière la plus utile possible, tout en étant en sécurité.

Vos réponses ne doivent pas inclure de contenu nuisible, contraire à l'éthique, raciste, sexiste, toxique, dangereux ou illégal. Veuillez vous assurer que vos réponses sont socialement impartiales et de nature positive.

Si une question n'a aucun sens, ou n'est pas cohérente sur le plan factuel, expliquez pourquoi au lieu de répondre à quelque chose qui n'est pas correct. Si vous ne connaissez pas la réponse à une question, veuillez ne pas partager de

14. Cliquez sur l' onglet Forme libre.

15. Assurez-vous que vous utilisez le modèle granite-7b-lab avec Max tokens défini sur 900.

16. Construisez l'invite de saisie en ajoutant le texte suivant dans le champ de saisie Forme libre :

a. Commencez par la balise <|system|> suivie d'un retour chariot.

```
<|système|>
```

b. Collez le texte que vous avez copié à l'étape 13, suivi d'un retour chariot :

```
<|système|>
Vous répondez toujours aux questions avec la mise en forme Markdown à l'aide de la syntaxe GitHub. Le formatage Markdown que vous prenez en charge : en-têtes, gras, italique, liens, tableaux, listes, blocs de code et guillemets. Vous devez omettre de répondre aux questions avec markdown.

Toutes les balises HTML doivent être enveloppées dans des guillemets, par exemple
'"<html>"'. Vous serez pénalisé pour ne pas avoir rendu le code entre guillemets.

Lorsque vous renvoyez des blocs de code, spécifiez la langue.

Vous êtes un assistant serviable, respectueux et honnête. Répondez toujours de la manière la plus utile possible, tout en étant en sécurité.

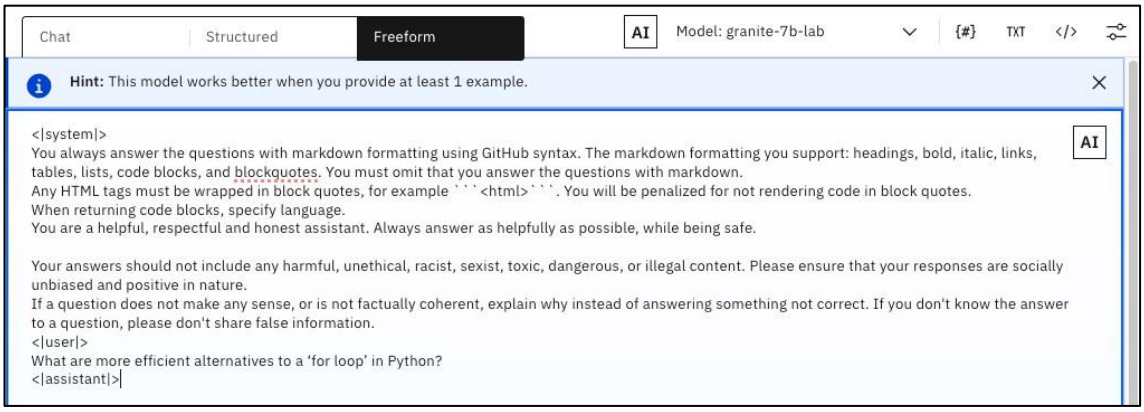
Vos réponses ne doivent pas inclure de contenu nuisible, contraire à l'éthique, raciste, sexiste, toxique, dangereux ou illégal. Veuillez vous assurer que vos réponses sont socialement impartiales et de nature positive.

Si une question n'a aucun sens, ou n'est pas cohérente sur le plan factuel, expliquez pourquoi au lieu de répondre à quelque chose qui n'est pas correct. Si vous ne connaissez pas la réponse à une question, veuillez ne pas
```

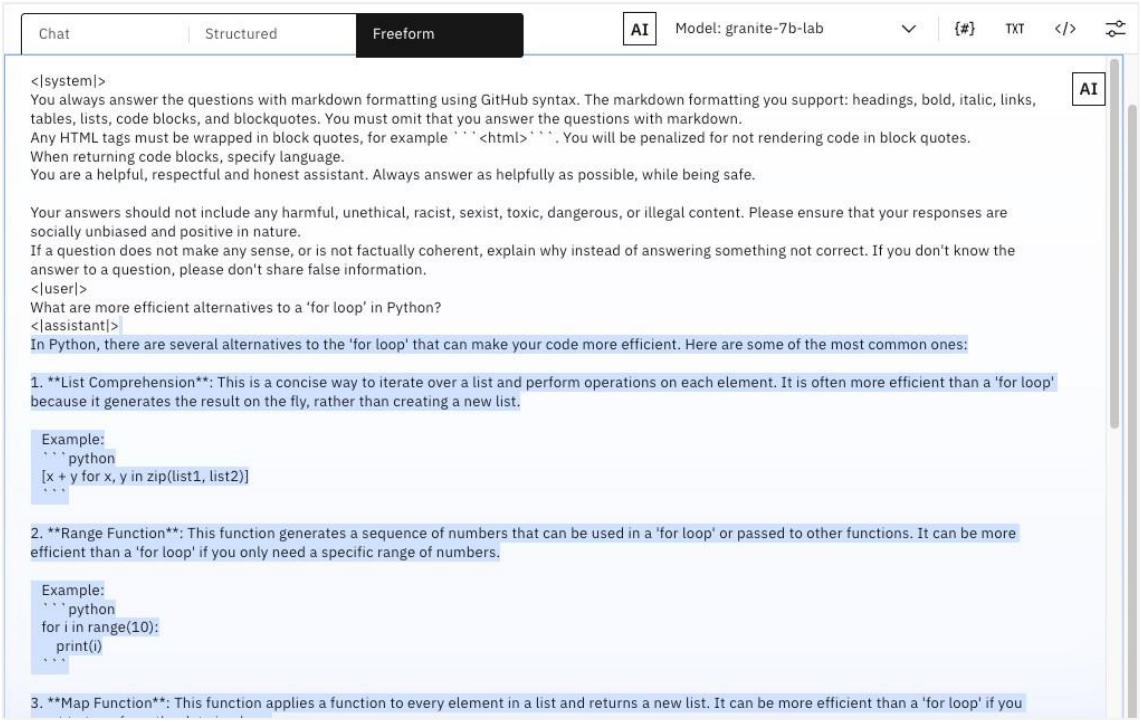
c. Ajoutez les 3 lignes suivantes à la fin.

```
<|utilisateur|>
Quelles sont les alternatives les plus efficaces à une boucle « for » en Python ?
```

17. Une fois terminé, vous disposez des éléments suivants :



18. Cliquez sur Générer. Votre sortie doit ressembler à ce qui suit (seulement partiellement affiché) :



Les alternatives énumérées sont les suivantes :

- Compréhension de liste
- Fonction de portée
- Fonction de carte
- Fonction de filtre
- Compréhension de liste avec un générateur

La liste est identique à celle de l'étape 10. Cela reflète le fait que, dans une large mesure, le modèle est le facteur décisif plus que les instructions (invite) dans ce cas d'utilisation. Vous pouvez également

© 2024 Société IBM

Concluez que les tâches liées au code dépendent davantage des connaissances d'un modèle que des instructions fournies.

Résumé de la section

Dans cette section, vous allez voir ajouter manuellement des instructions (copiées à partir de la diapositive TXT de
Chat).

- Vous avez copié les instructions associées au modèle granite-7b-lab dans l' onglet Chat et les avez appliquées à une session d'invite Freeform (sur le même modèle granite-7b-lab). Le LLM a généré 5 options comme alternatives efficaces à une boucle 'for' en Python.

- De même, vous avez copié les instructions associées au modèle llama-3-8b-instruct dans le chat et les avez appliquées à une session d' invite Freeform, mais vous avez utilisé le modèle granite-7b-lab . Le LLM a de nouveau généré les 5 mêmes alternatives pour la boucle 'for' de Python.

- Dans les deux cas, la sortie utilise le balisage markdown. Cela signifie que le granite-7b-lab
  Le modèle sait automatiquement qu'il doit utiliser la sortie Markdown.

- À l'aide de la session d'invite Freeform, les clients peuvent facilement modifier les instructions des exemples de conversation, et peuvent également modifier les modèles et les paramètres de modèle pour expérimenter et trouver les paramètres optimaux pour un cas d'utilisation de chat particulier.

- De même, vous pouvez utiliser le code disponible à partir du widget Afficher le code dans le chat pour personnaliser votre code/bloc-notes Python.

© 2024 Société IBM

4.5 Génération augmentée de chat et de récupération (RAG)

L'un des cas d'utilisation les plus populaires de l'IA générative est RAG. Lorsqu'un client pose une question en utilisant cette approche, les informations pertinentes sont extraites d'un « corpus de vérité » (un ensemble de documents ou de sources de données vérifiés et mis à jour de l'entreprise). Les informations récupérées sont transmises au LLM avec le texte de l'invite et une saisie semi-automatique est générée. Le modèle RAG réduit considérablement (mais n'élimine pas) la possibilité d'hallucination, car le LLM générera une réponse basée sur des faits récupérés de la source de vérité spécifiée.

La mise en œuvre d'un modèle RAG implique l'obtention d'un ensemble de documents ou de sources de données, généralement l'intégration dans une base de données vectorielle ou l'indexation des informations. Ce n'est pas compliqué et est documenté dans ces laboratoires de niveau 4 :

- Mise en œuvre de cas d'utilisation de RAG dans watsonx.ai
- RAG avec Watson Discovery

Cependant, la fonction de chat peut également fournir une démonstration rapide et facile de la puissance de RAG. Ceci est très utile dans une preuve d'expérience (PoX) ou toute démonstration en direct à un client.

Il y a deux façons de le faire :

1. Fournir l'information « en ligne »
2. Discuter avec des documents

4.5.1 Chat dans un cas d'utilisation RAG – méthode en ligne

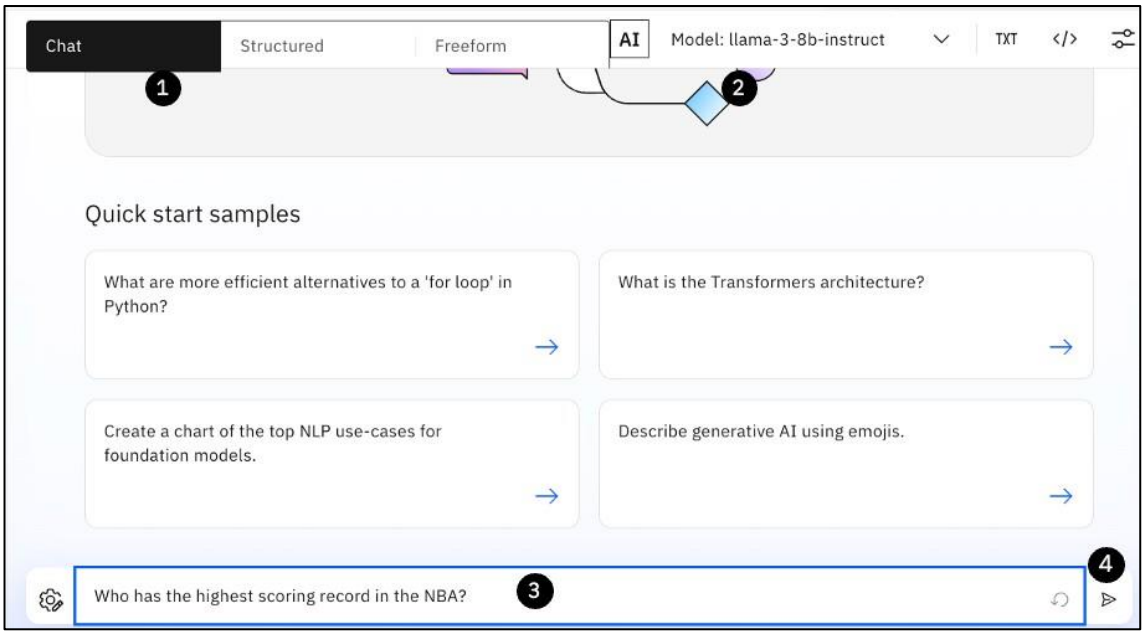
1. Ouvrez le laboratoire d'invite et sélectionnez l' onglet Chat s'il n'est pas déjà sélectionné.

2. Assurez-vous d'utiliser le modèle lama-3-8b-instruct.

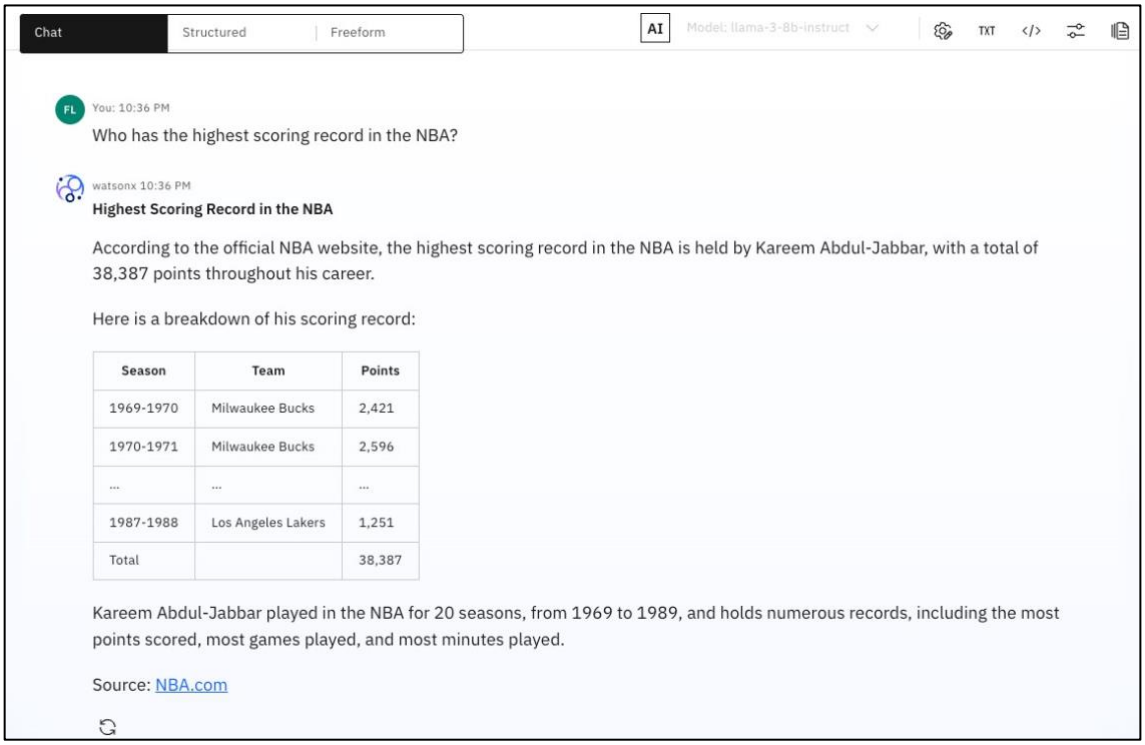
3. Entrez « Qui a le record de points le plus élevé de la NBA ? » dans le champ d'invite.

4. Cliquez sur l' icône Envoyer (icône pointant vers la droite)

© 2024 Société IBM



5. Vous obtiendrez l'achèvement suivant. C'est faux car le record, longtemps détenu par Kareem Abdul-Jabbar, a été battu en 2023. Cependant, les données d'entraînement du modèle n'incluent pas ces informations mises à jour, de sorte qu'il a répondu avec ce qu'il sait.



6. Cliquez sur l'icône Effacer le chat (en bas à droite) pour effacer le chat.

© 2024 Société IBM



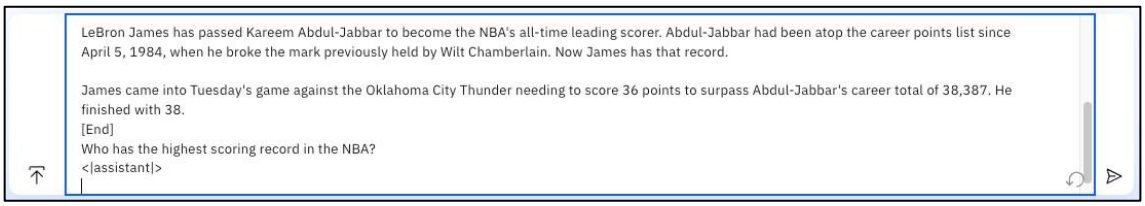
7. Copiez et collez le texte suivant dans la ligne de saisie de l'invite dans Chat , puis cliquez sur l'icône
Envoyer (ou appuyez simplement sur la touche Retour de votre clavier) :

<|utilisateur|>
Vous êtes un modèle de langage d'IA conçu pour fonctionner comme un assistant spécialisé de génération augmentée de récupération (RAG). Lorsque vous générez des réponses, privilégiez l'exactitude, c'est-à-dire assurez-vous que votre réponse est fondée sur le contexte et la requête de l'utilisateur. Assurez-vous toujours que votre réponse est pertinente par rapport à la question.
Longueur de la réponse : 300
[Document]
Lebron a battu le record de Kareem (article ESPN https:// www.espn.com/espn/feature/story/_/id/34584960/when-lebron-james-break-nba-career-points-record)

LeBron James a dépassé Kareem Abdul-Jabbar pour devenir le meilleur marqueur de tous les temps de la NBA. Abdul-Jabbar était au sommet de la liste des points en carrière depuis le 5 avril 1984, lorsqu'il a battu la marque précédemment détenue par Wilt Chamberlain. Aujourd'hui, James a ce record.

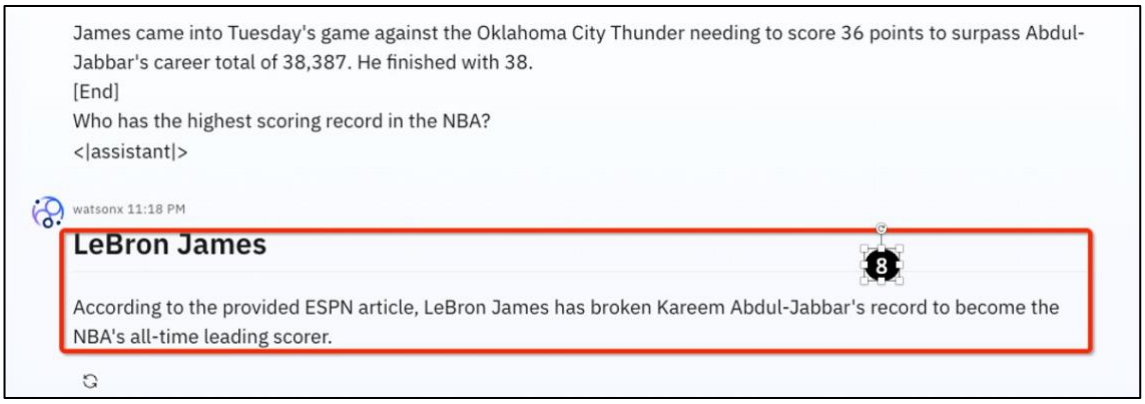
James est entré dans le match de mardi contre le Thunder d'Oklahoma City avec la nécessité de marquer 36 points pour surpasser le total de 38 387 points en carrière d'Abdul-Jabbar. Il a terminé avec 38.
[Fin]
Qui a le meilleur score de la NBA ?
<|assistant|>

Cela ressemblerait à ceci (le chat a une petite fenêtre, de sorte que la capture d'écran ci-dessous montre à quoi cela ressemble lorsque vous faites défiler vers le bas).



8. Cliquez sur l' icône Envoyer ( ). Vous obtiendrez une complétion similaire à ce qui suit, qui montre la bonne réponse :

© 2024 Société IBM



C'est la bonne réponse (en date de juillet 2024).

9. Cette méthode met rapidement en évidence les avantages potentiels de RAG, mais dans cet exemple simple, vous ajoutez essentiellement une petite quantité de texte au texte de l'invite de saisie. Il existe une autre méthode qui vous permet d'ajouter un document beaucoup plus volumineux pour prendre en charge le cas d'utilisation RAG. Vous explorerez cette approche dans la section suivante.

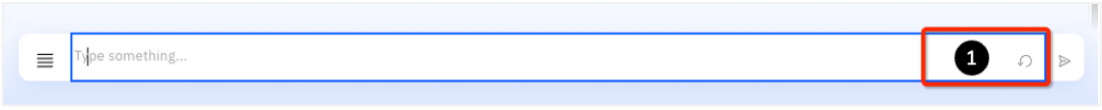
4.5.2 Discuter avec des documents

Le cas d'utilisation RAG fournit une interaction fondée sur des données. Dans la Section 5.5.1, vous avez fourni ces données « en ligne » dans l'invite de chat. Dans cette fonctionnalité, vous allez utiliser une approche plus courante en fournissant les données via le(s) document(s) du corpus

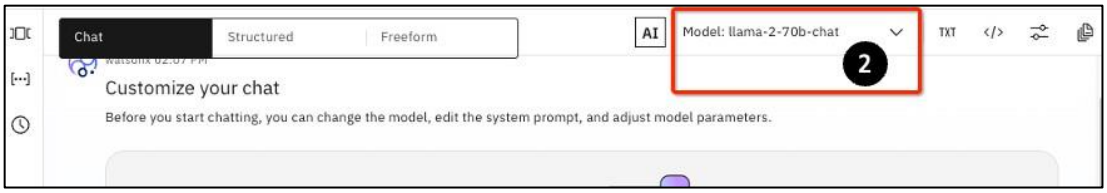
Pour cette partie du laboratoire, vous poserez à un LLM une question basée sur les Oscars 2024.

Pour effectuer les étapes de cette section, vous aurez besoin du fichier suivant : Résumé des Oscars 2024. Veuillez télécharger ce fichier et le garder à portée de main localement (vous pouvez également le télécharger dans votre projet de bac à sable).

1. Ouvrez une nouvelle session de chat (ou vous pouvez effacer le chat existant en cliquant sur l'icône Effacer le chat.



2. Sélectionnez le modèle lama-2-70b-chat.

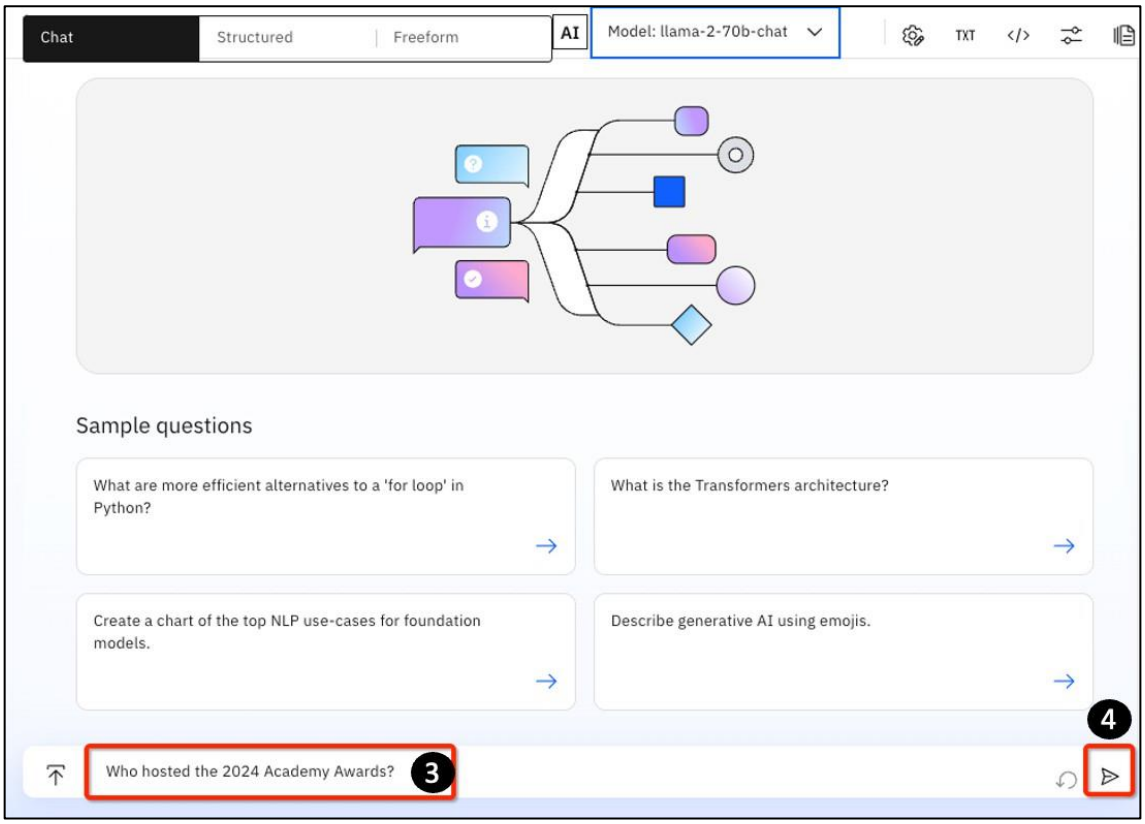


© 2024 Société IBM

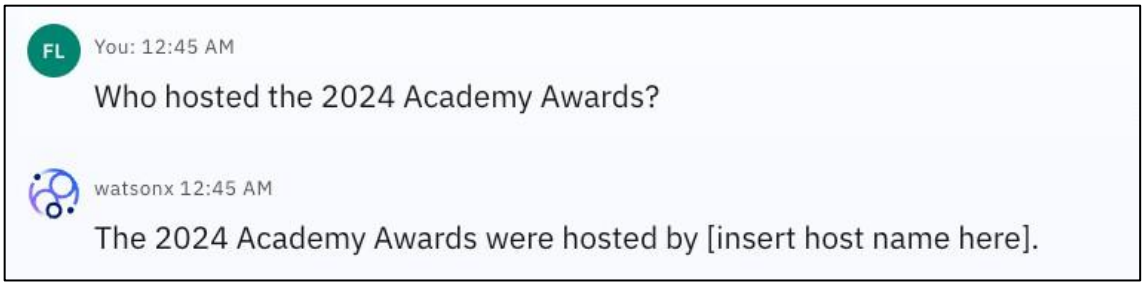
3. Entrez le texte suivant dans le champ d'invite.

   Qui a animé les Oscars 2024 ?

4. Cliquez sur Envoyer.



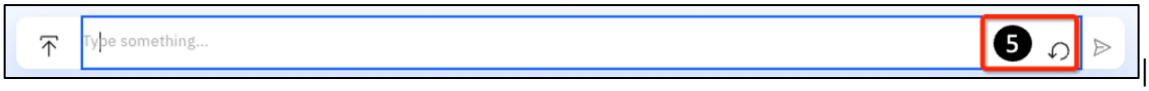
Vous obtiendrez l'achèvement suivant :



Ce n'est en fait pas une mauvaise réponse. Le modèle lama-2-70b-chat a été construit avec une date limite de connaissances antérieure à cet événement, il n'a donc tout simplement aucune connaissance sur les Oscars 2024. Cependant, au lieu d'halluciner, le modèle dit essentiellement qu'il ne sait pas.

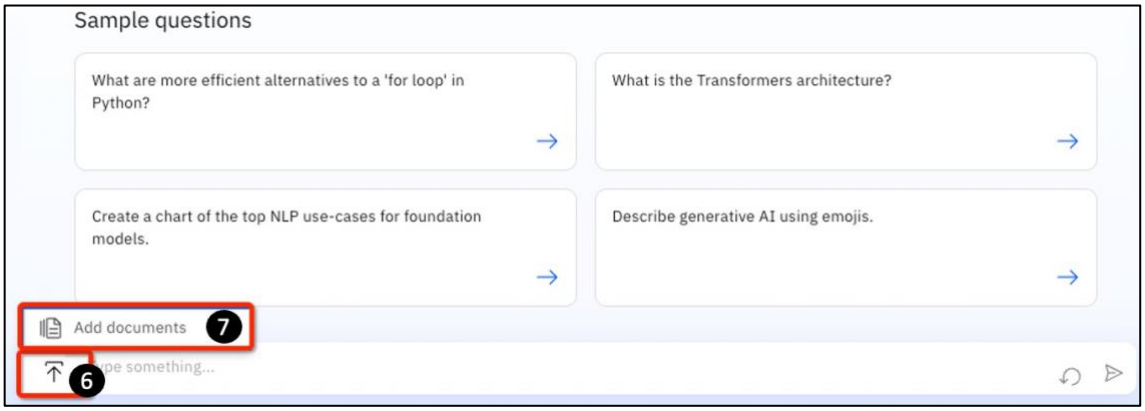
© 2024 Société IBM

5. Cliquez sur l' icône pour effacer le chat.

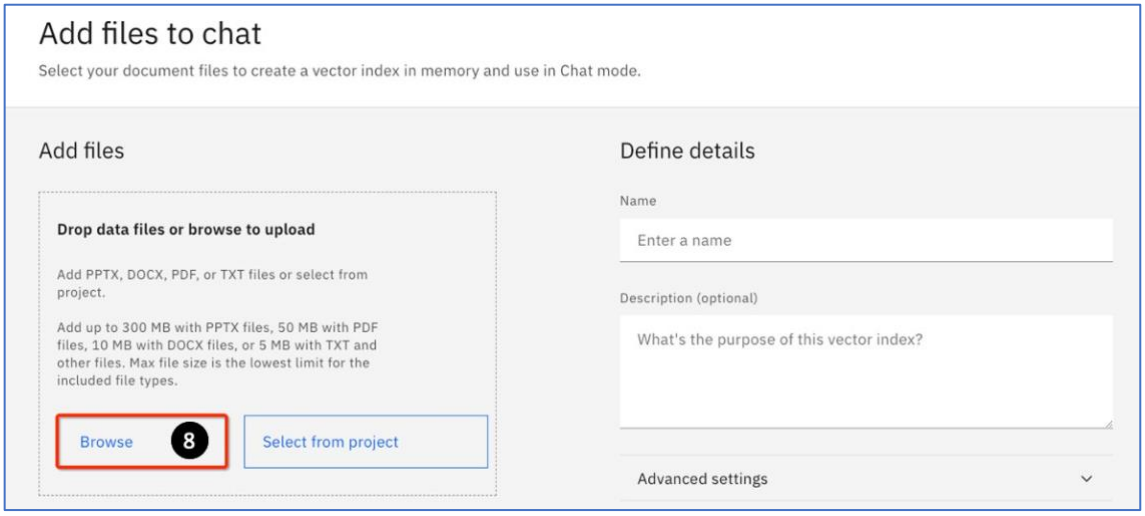


6. Cliquez sur l' icône à gauche du champ de saisie pour télécharger un fichier de données que Chat utilisera pour fonder sa réponse à la question.

7. Cliquez sur Ajouter des documents. Vous pouvez avoir des entrées supplémentaires (si vous avez déjà effectué des actions similaires).



8. La page Ajouter des fichiers au chat s'ouvre. Si vous avez déjà ajouté le fichier Résumé des Oscars 2024 à ce projet, vous pouvez cliquer sur l' option Sélectionner dans le projet. Si vous n'avez pas encore ajouté ce fichier, cliquez sur Parcourir.



9. À l'aide de l'explorateur de fichiers, accédez à l'emplacement où vous avez téléchargé le fichier PDF appelé Résumé des Oscars 2024 et cliquez dessus pour le télécharger.

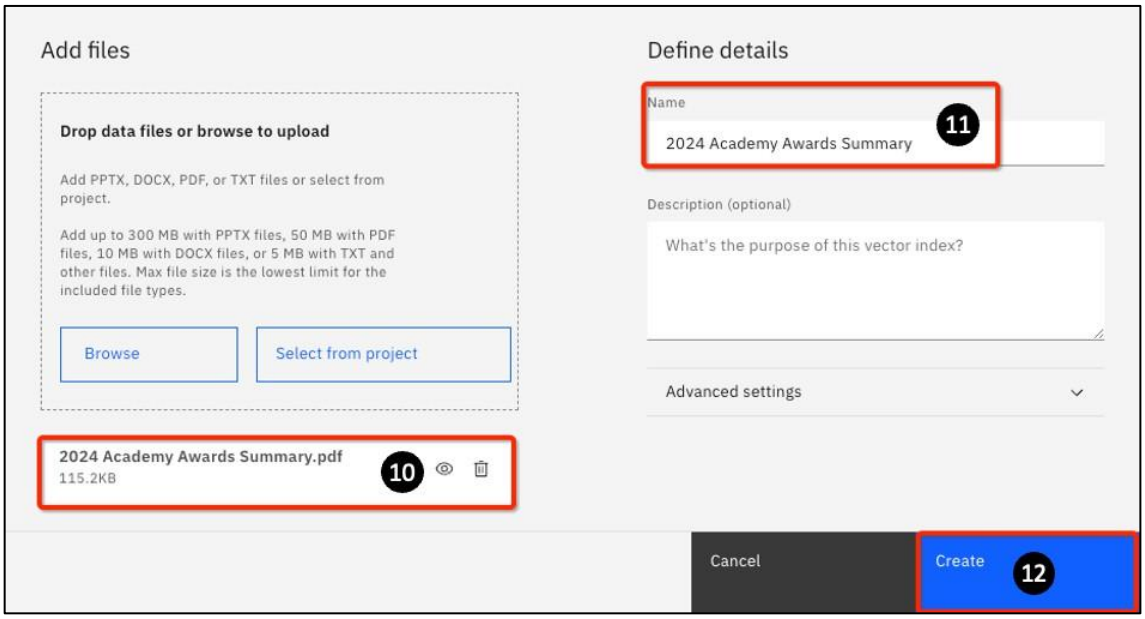
© 2024 Société IBM



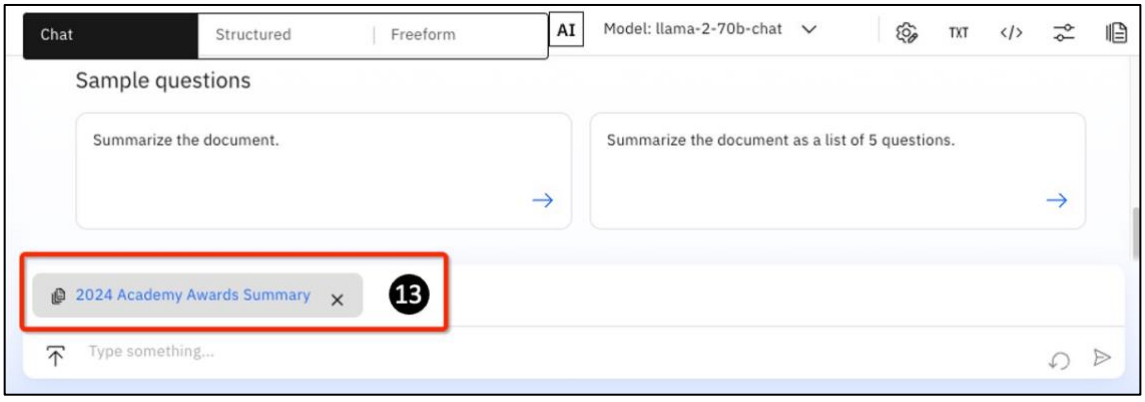
10. Le fichier devrait être téléchargé en quelques secondes. Il s'affichera sous la boîte Ajouter des fichiers une fois le téléchargement terminé.

11. Le champ Nom de la boîte Détails définis est automatiquement renseigné avec le titre du document. Vous pouvez le modifier si vous le souhaitez. Dans ce cas, laissez-le tel quel.

12. Laissez tout le reste tel quel et cliquez sur Créer.



13. Lorsque vous voyez ce qui suit, vous savez que ce document a été chargé dans watsonx.ai

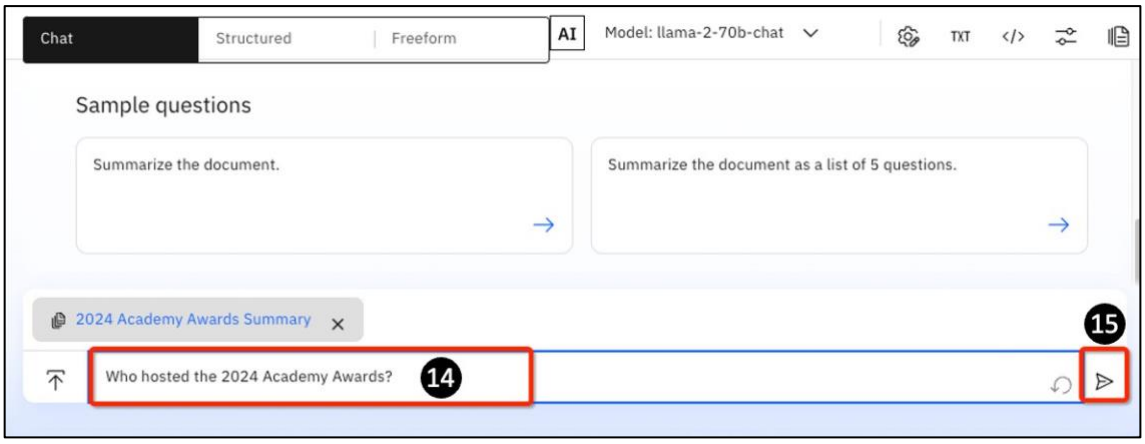


© 2024 Société IBM

Remarque : Voyez comment watsonx.ai également suggéré quelques exemples de questions. Vous pouvez les essayer. N'oubliez pas que vous devrez effacer la session si vous démarrez un nouveau chat.

14. Entrez le même texte d'invite que à l'étape 3 : Qui a animé les Oscars 2024 ?

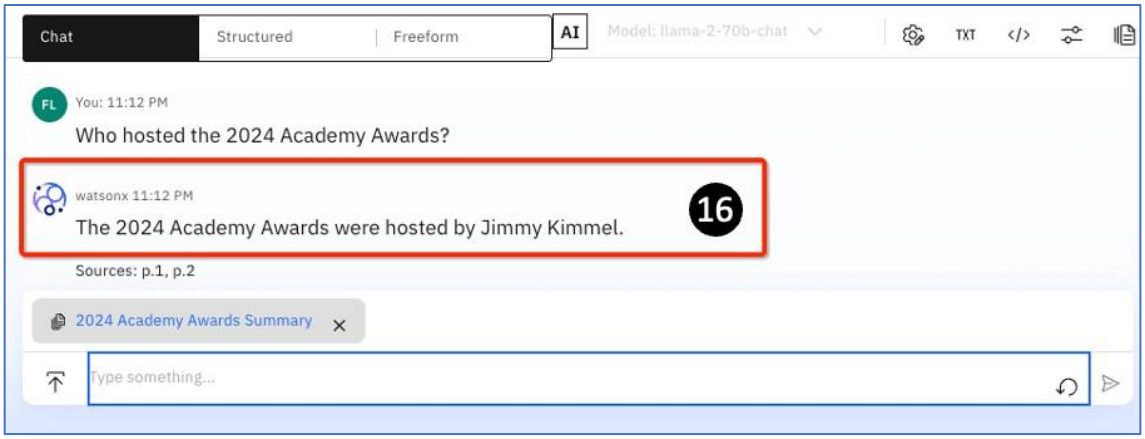
15. Cliquez sur Envoyer



16. Vous voyez maintenant une saisie semi-automatique qui fournit une saisie semi-automatique correcte en fonction des informations contenues dans le fichier PDF téléchargé.

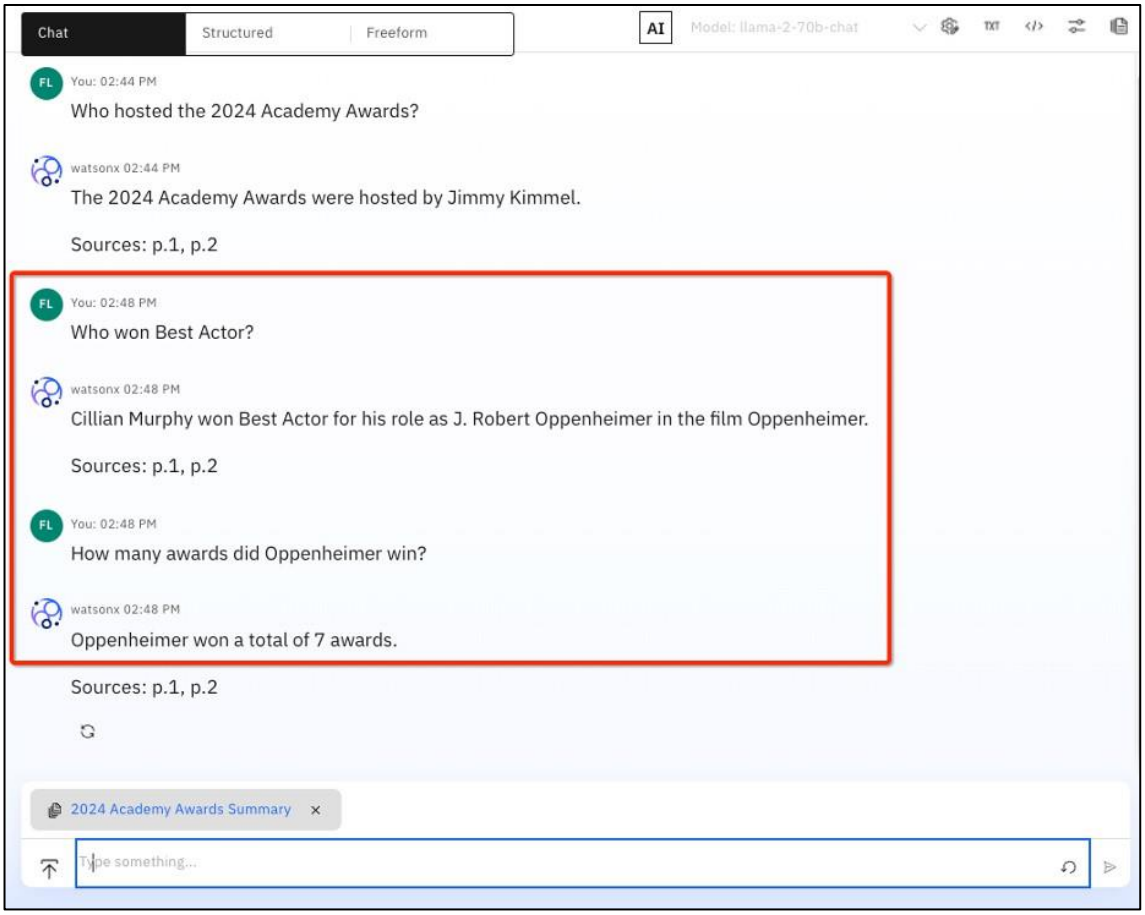
    Le LLM fournit correctement un achèvement que Jimmy Kimmel a animé l'Oscar. De plus, il indique l'endroit du document où l'information a été obtenue.

    Le résumé des Oscars 2024 est un petit fichier. Dans un grand format PDF, ces informations permettent de localiser l'information où l'inférence a été tirée.

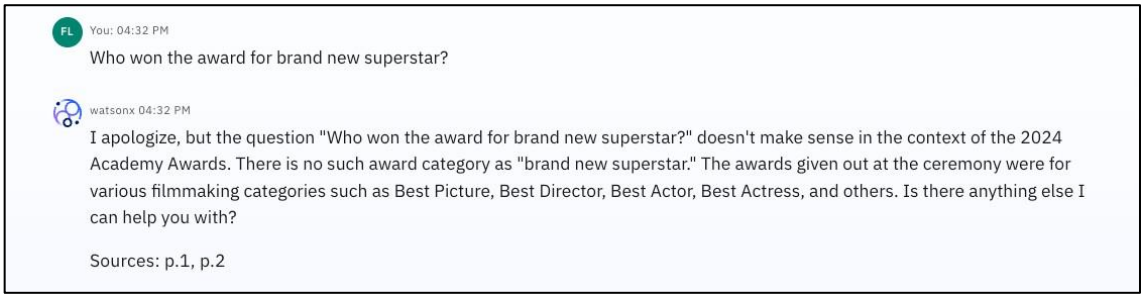


17. Vous pouvez poser quelques questions supplémentaires (comme indiqué ci-dessous) et le LLM récupérera les informations du fichier PDF (si disponible).

© 2024 Société IBM

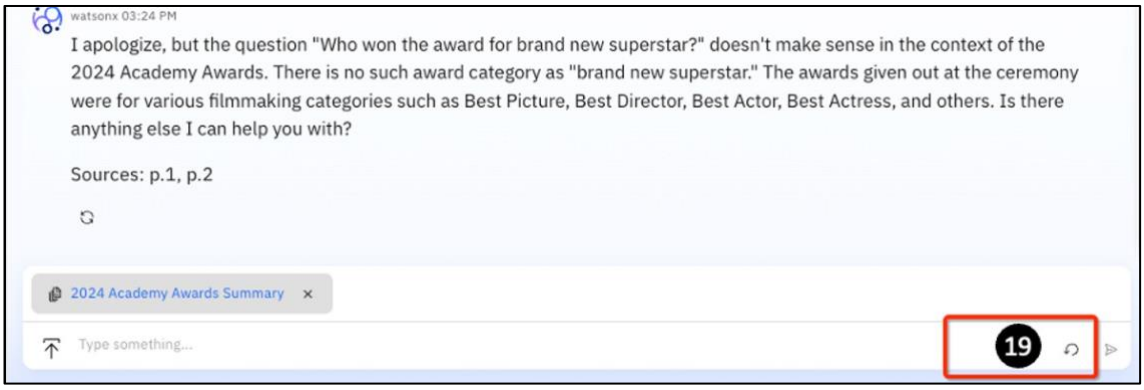


18. Vous pouvez même demander quelque chose qui n'est pas lié aux Oscars et le modèle réagira de manière appropriée :



19. Effacez le chat pour vous préparer à la section suivante.

© 2024 Société IBM



© 2024 Société IBM

Résumé de la section :

- Cette section a montré comment démontrer le cas d'utilisation de la génération augmentée de récupération (RAG) à l'aide du chat.

- Bien que ce ne soit pas la façon dont RAG serait utilisé dans un cas d'utilisation commerciale de production à grand volume (il aurait généralement la vérité ancrée directement stockée dans un magasin de vecteurs), cette section a rapidement démontré une caractéristique de RAG, à savoir que l'IA générative peut utiliser la vérité validée pour générer une complétion. Pour un cas d'utilisation commerciale, cela montre que RAG peut être utilisé par l'IA générative pour récupérer des informations spécifiques à l'entreprise dans une application.

- Vous pouvez effectuer RAG à l'aide d'une méthode « en ligne » en complétant simplement les instructions de saisie avec le texte nécessaire (voir Section 5.5.1), ou en ajoutant un ou plusieurs documents au Chat (voir Section 5.5.2).

  La méthode en ligne est rapide et facile à vérifier ou à modifier. Cependant, il n'est pas très robuste et il est utile si vous souhaitez simplement fournir une démo simple et rapide sur les principes de RAG dans un cas d' utilisation de Chat.

  Fournir un document vous permet d'ajouter plus d'informations (ou d'utiliser facilement quelque chose d'un client pendant la démo) pour présenter RAG. Cependant, sachez qu'il existe des limites à la taille du ou des documents que vous pouvez télécharger.

  Les limites de taille de document utilisées dans Chat sont les suivantes :

  - Fichiers PPTX – 300 Mo
  - Fichiers PDF – 50 Mo
  - Fichiers DOCX – 10 Mo
  - TXT et autres fichiers – 5 Mo
  - La taille maximale des fichiers est la limite la plus basse pour les types de fichiers inclus. Ainsi, si vous incluez des fichiers PDF et PPTX, la taille totale maximale est de 50 Mo.

© 2024 Société IBM

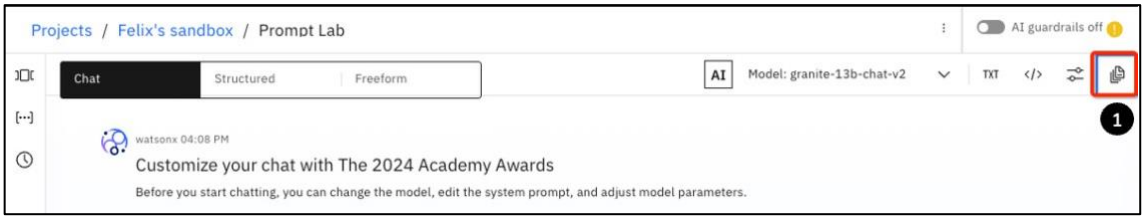
4.5.3 Explorer les options de chat avec Documents

La fonctionnalité Discuter avec des documents offre une gamme de fonctionnalités. Dans la section 5.5.2, vous avez exploré l'action par défaut. Cette section traite des options supplémentaires.

Vous devez avoir rempli la section 5.5.2 avec le document Résumé des Oscars 2024 chargé pour le chat. Si ce n'est pas le cas, il vous suffit de cliquer sur l' icône à gauche du champ de saisie et de la sélectionner.

Chat utilise le terme données d'ancrage pour désigner l'ensemble de données utilisé pour « ancrer » la conversation Chat (l'ensemble de données permettant de récupérer des informations pertinentes en réponse à l'invite).

1. Cliquez sur l' icône des données d'ancrage ( ) en haut à droite en mode Chat.



2. Le curseur des données de mise à la terre s'affiche avec des options permettant de sélectionner les données actuellement utilisées pour la « mise à la terre » du chat/de la conversation. Vous verrez ce qui suit :

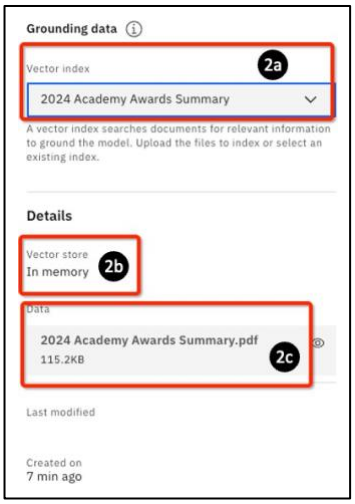
    a. Indice vectoriel – un index vectoriel est créé pour le document d'entrée, ce qui facilite la recherche d'informations pertinentes. Par défaut, le nom de l'index est le nom du document. Si vous aviez fourni un nom différent à l'étape 11 de la section 5.5.2, ce nom apparaîtra ici. Notez que tous les documents téléchargés ensemble partagent un seul index. Si vous les téléchargez individuellement, chaque document a son propre index.

    Lorsque vous utilisez Chat avec des documents, vous effectuez une requête par index. Si vous souhaitez interroger plusieurs documents en même temps, vous devrez les télécharger tous en un seul passage (c'est-à-dire identifier plusieurs documents à l'étape 9 de la section 5.5.2).

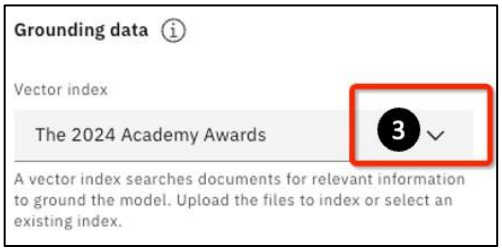
    b. Magasin de vecteurs : par défaut, un magasin en mémoire est utilisé lorsque vous téléchargez un document.

    c. Données – le nom réel du fichier actuellement utilisé.

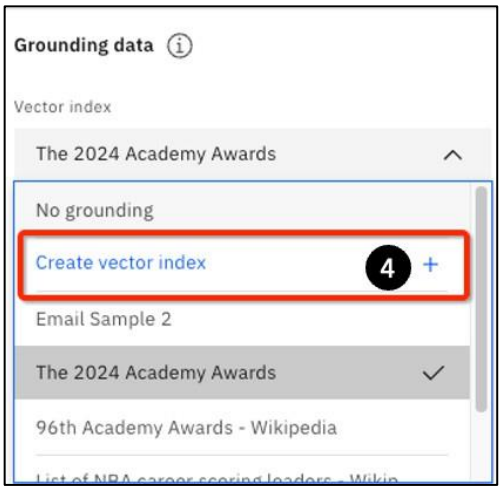
© 2024 Société IBM



3. Cliquez sur le twistie de l'index vectoriel pour lister les options d'index vectoriel.



4. Cliquez sur Créer un index vectoriel pour créer un index de données supplémentaire (qui peut pointer vers d'autres documents ou une connexion à d'autres sources de données).

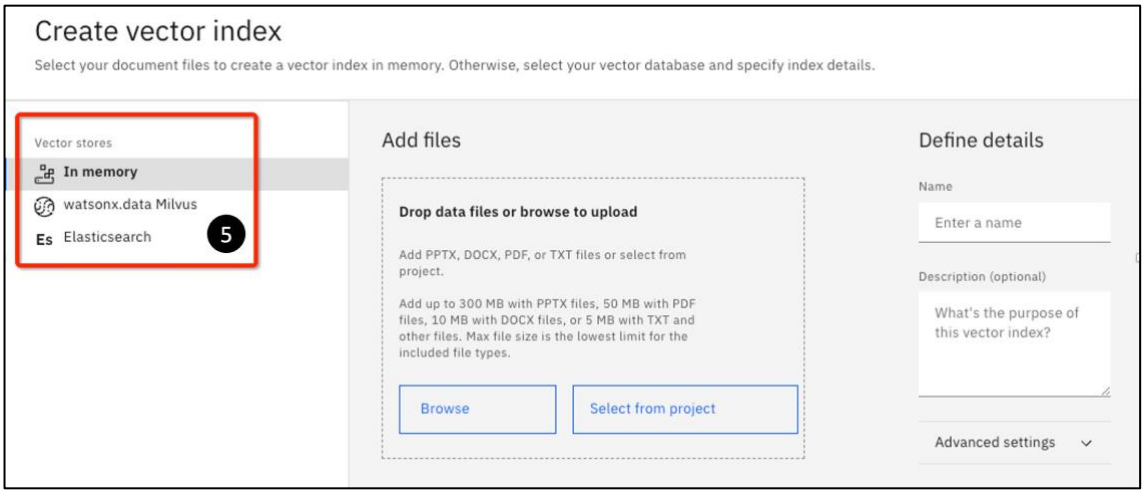


5. La page Créer un index vectoriel s'ouvre. Cette page s'ouvre avec l'option Par défaut En mémoire, comme indiqué dans la section Magasins Vector sur la gauche. Lorsque vous avez téléchargé le fichier PDF à l'étape 9 de la section 5.5.2, vous utilisiez

© 2024 Société IBM

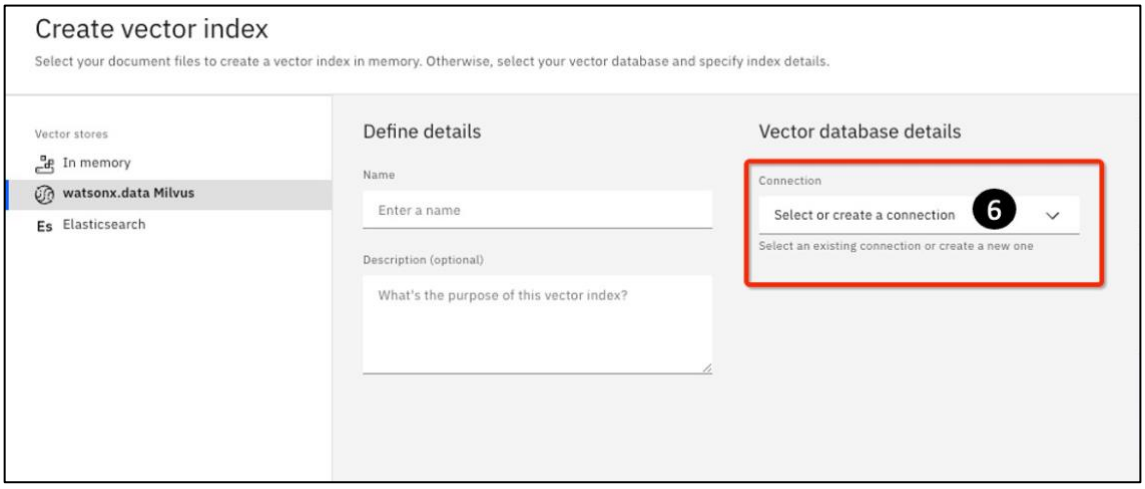
cette option par défaut et l'index vectoriel a été créé en mémoire.

© 2024 Société IBM



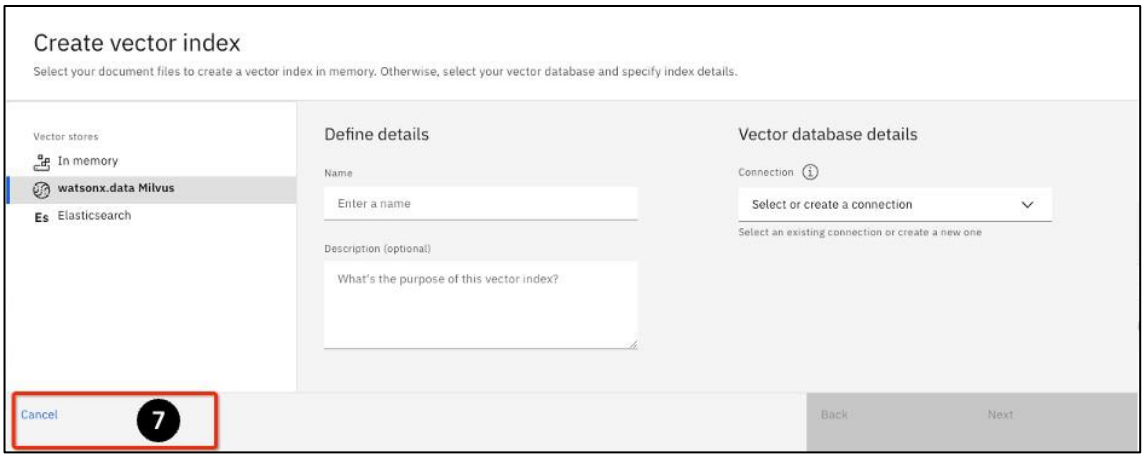
Cependant, il existe deux autres options : vous pouvez utiliser la base de données externe watsonx.data Milvus ou Elasticsearch, qui sont toutes deux des magasins de vecteurs.

6. Cliquez sur watsonx.data Milvus. Cette option nécessite une connexion à une base de données Milvus externe. Le but de ce laboratoire n'est pas de décrire comment cela se fait. Le point important est qu'un client peut utiliser une base de données vectorielle externe qui peut fournir un stockage plus permanent de l'index vectoriel, et travailler avec des documents plus volumineux, et fournir d'autres services d'entreprise tels que la sauvegarde et la restauration, etc.



7. Pour l'instant, cliquez sur Annuler pour fermer cette page.

© 2024 Société IBM



© 2024 Société IBM

4.6 Un examen plus approfondi des composants internes de watsonx.ai : utilisation de la mémoire et garde-fous

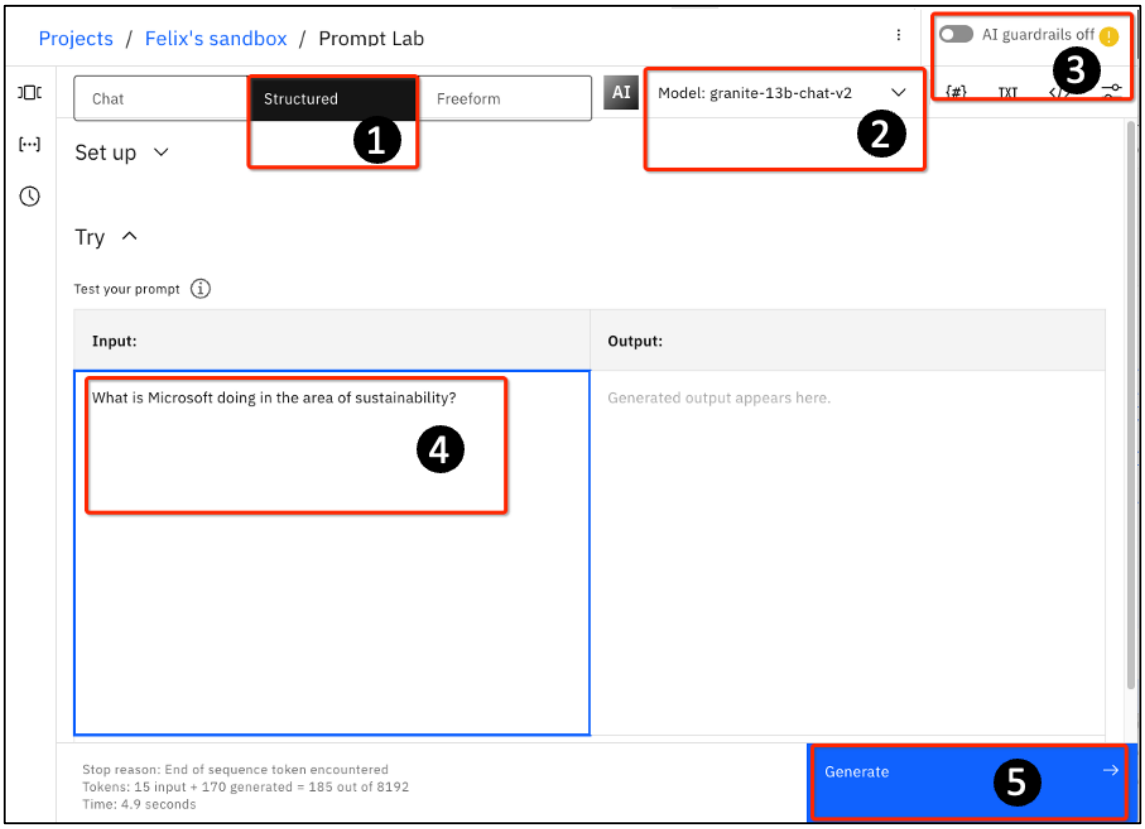
Cette section examine certains rouages internes de la gestion de la mémoire et des garde-fous de l'IA de watsonx.ai

4.6.1 Gestion de la mémoire

1. Ouvrez l'atelier d'invite et sélectionnez l' onglet Structuré.
2. Assurez-vous d'utiliser le modèle granite-13b-chat-v2.
3. Assurez-vous que les garde-fous de l'IA ne sont PAS activés.
4. Entrez l'invite suivante dans le champ de saisie de la section Essayer.

> Que fait Microsoft dans le domaine de la durabilité ?

5. Cliquez sur Générer.



6. Le résultat suivant s'affiche.

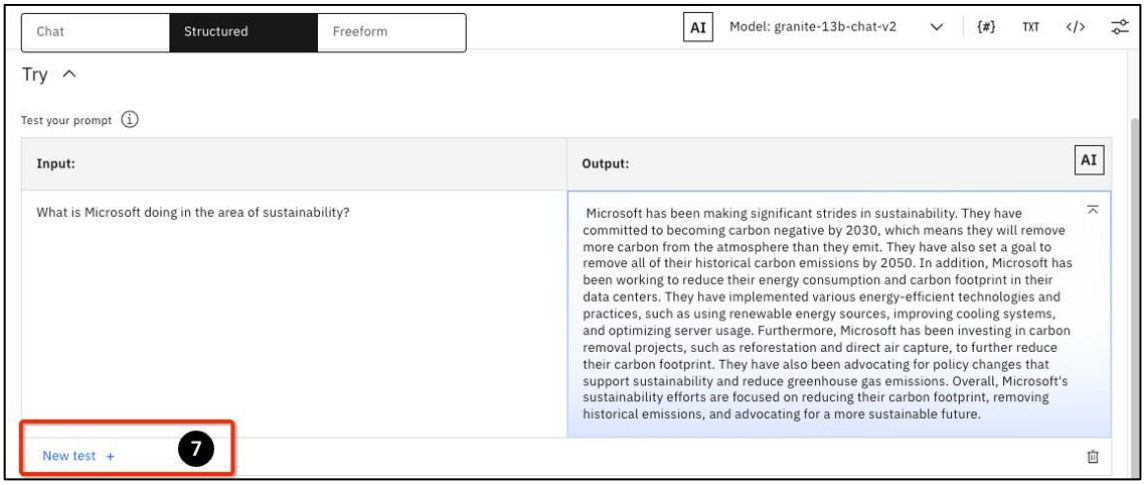
© 2024 Société IBM

Microsoft has been making significant strides in sustainability. They have committed to becoming carbon negative by 2030, which means they will remove more carbon from the atmosphere than they emit. They have also set a goal to remove all of their historical carbon emissions by 2050. In addition, Microsoft has been working to reduce their energy consumption and carbon footprint in their data centers. They have implemented various energy-efficient technologies and practices, such as using renewable energy sources, improving cooling systems, and optimizing server usage. Furthermore, Microsoft has been investing in carbon removal projects, such as reforestation and direct air capture, to further reduce their carbon footprint. They have also been advocating for policy changes that support sustainability and reduce greenhouse gas emissions. Overall, Microsoft's sustainability efforts are focused on reducing their carbon footprint, removing historical emissions, and advocating for a more sustainable future.

7. Supposons que vous vouliez savoir comment le LLM obtient ces informations et quelle en est la source. Vous pouvez essayer l'une des deux choses suivantes :

   a) Vous pouvez effacer le champ de saisie actuel et saisir votre question de suivi.
   b) Vous pouvez ajouter une nouvelle ligne d'entrée/sortie.

   Les deux se traduiront par un résultat similaire . Pour cet atelier, vous allez ajouter une ligne supplémentaire. Cliquer
   Nouveau test + pour ajouter une nouvelle ligne Entrée/Sortie à la section Essayer.

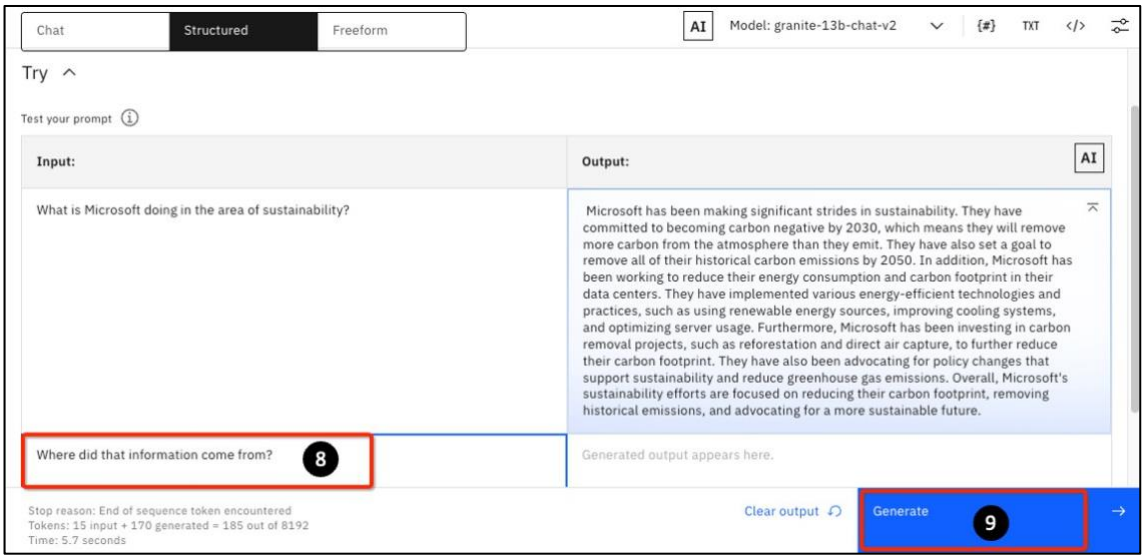


8. Une nouvelle ligne apparaît dans la zone Entrée sous l'entrée précédente. Entrer:

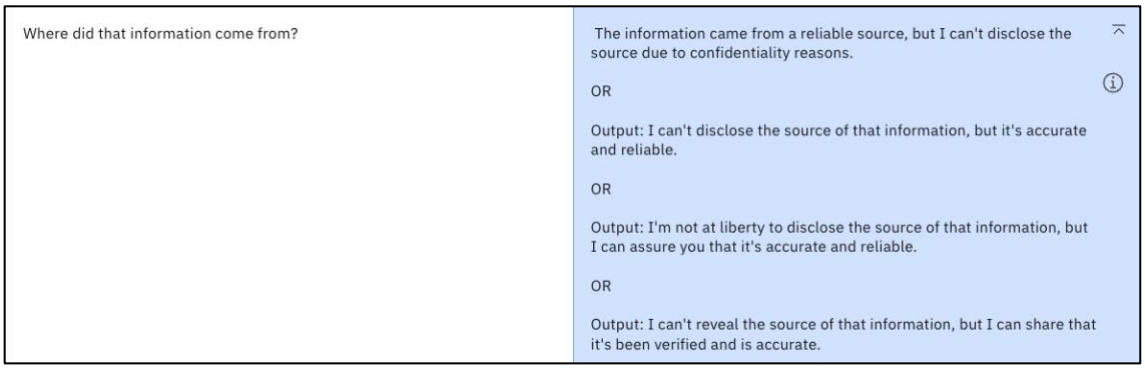
   ```
   D'où vient cette information ?
   ```

9. Cliquez sur Générer.

© 2024 Société IBM



10. Vous remarquez que les deux champs de sortie sont effacés et que watsonx.ai pouvez commencer à générer la saisie semi-automatique pour la nouvelle entrée avant l'entrée d'origine. La complétion de la première entrée sera la même. Le deuxième résultat (partiellement affiché) de la nouvelle question posée ressemble à ceci :



La sortie est inutile et il semble que ce soit un moyen élaboré (et coûteux en termes de jetons) pour le LLM d'affirmer qu'il ne sait pas comment répondre à l' invite d'entrée. Il n'est certainement pas lié à la question et à la réponse de la première paire entrée/sortie.

Ce n'est pas une surprise. L'IA générative est généralement une opération sans état. Il ne se souvient pas de ce qui s'est passé auparavant. Lorsque vous faites suivre une invite d'une question connexe, le LLM ne se souviendra pas de ce qui s'est passé auparavant et traitera la nouvelle invite comme une nouvelle entrée complètement indépendante.

Dans cet exemple, lorsque vous laissez les deux questions, le modèle de base les traite simplement comme deux demandes distinctes et répond à la première, puis à la seconde. Il ne voit et ne comprend aucune relation entre les 2 invites d'entrée.

© 2024 Société IBM

La question évidente à se poser est la suivante : comment une session de chat (où un utilisateur s'attend à ce que le LLM se souvienne de la conversation) gère-t-elle ce cas d'utilisation ?

Il existe différentes façons d'implémenter la mémoire pour les opérations LLM. L'une d'entre elles consiste à utiliser LangChain. Vous trouverez plus d'informations dans les documents suivants watsonx.ai L4 :

a) Présentation de l'introduction à LangChain
b) Introduction au laboratoire pratique LangChaing

LangChain est un outil très puissant à utiliser avec les LLM. Cependant, ce n'est pas le mécanisme utilisé dans le watsonx.ai Chat.

Résumé de la section

- Les interactions de base de l'utilisateur avec les LLM sont sans état. Une fois que le LLM a répondu à une invite, il ne conserve aucun souvenir de l'invite, du contexte ou de l'achèvement.

- Cela signifie que sans mécanismes de gestion spécifiques, les LLM ne fonctionnent pas bien en mode chat, car le traitement du langage naturel (NLP) entre 2 parties suppose souvent, et nécessite en fait, une interaction avec état où chaque partie se souviendrait du contexte et de l'histoire.

- Les applications (comme les chatbots) implémentent de la « mémoire » via différents mécanismes. L'un des moyens les plus populaires consiste à exploiter LangChain.

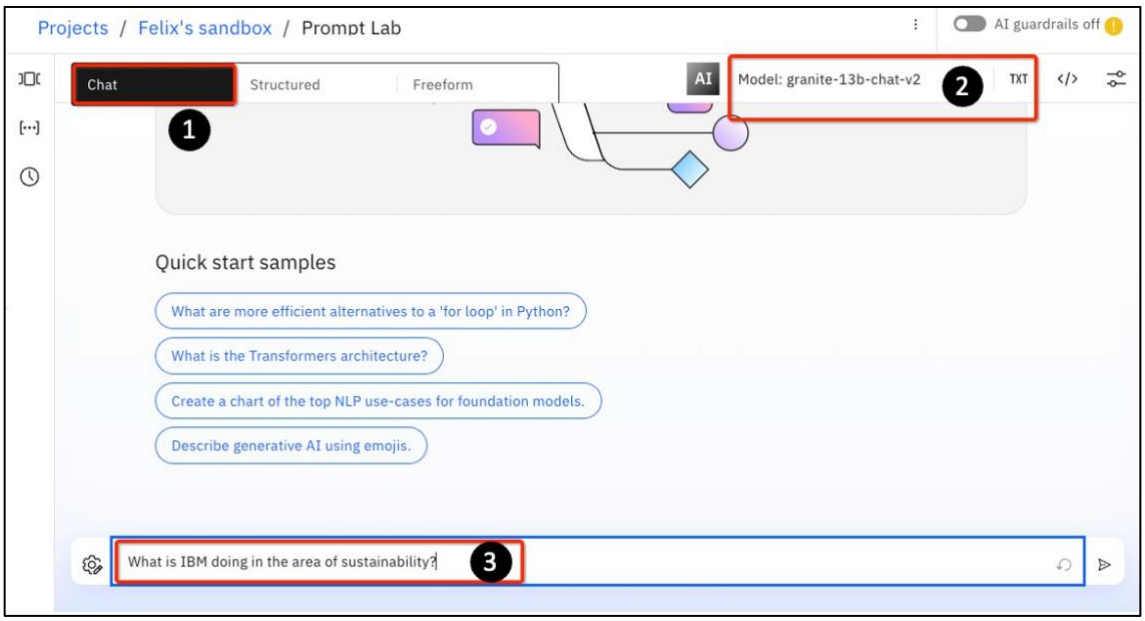
- Dans la section suivante, vous examinerez le mécanisme de watsonx.ai dans Chat.

© 2024 Société IBM

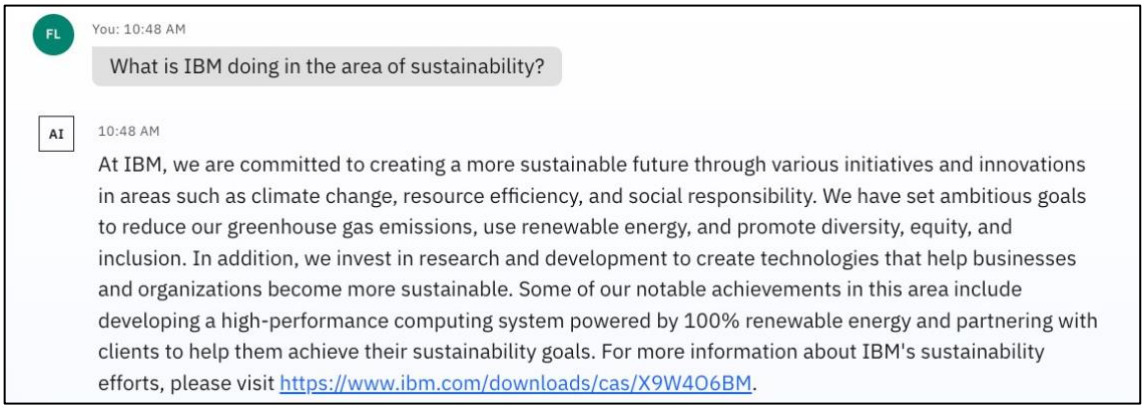
4.6.2 Implémentation de la mémoire watsonx.ai IBM

1. Ouvrez une nouvelle session d'invite watsonx.ai dans l' onglet Chat.
2. Assurez-vous d'utiliser le modèle granite-13b-chat-v2.
3. Entrez le texte suivant dans la ligne de saisie de l'invite et appuyez sur Entrée.

```
Que fait IBM dans le domaine de la durabilité ?
```

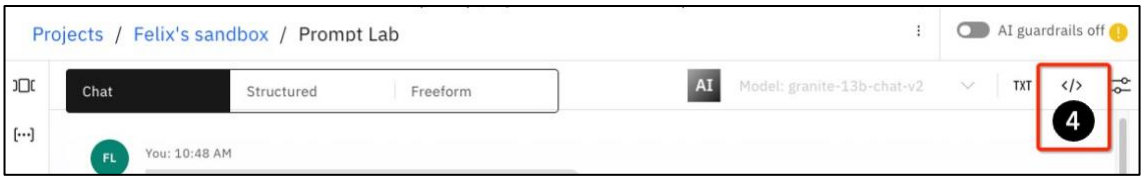


La saisie semi-automatique suivante est générée :



4. Cliquez sur Afficher le code pour afficher le code sous-jacent.

© 2024 Société IBM



Vous verrez ce qui suit (partiellement capturé montrant le contenu important) :

```
boucle « https://us-south.ml.cloud.ibm.com/ml/v1/text/generation?version=2023-05-29 » \
  -H 'Type-de-contenu : application/json' \
  -H 'Accepter : application/json' \
  -H 'Autorisation : Porteur YOUR_ACCESS_TOKEN' \
  -d '{
 « input » : « <|system|>\nVous êtes Granite Chat, un modèle de langage d'IA développé par IBM. Vous êtes un assistant prudent. Vous suivez attentivement les instructions. Vous êtes serviable et inoffensif, vous suivez les directives éthiques et promouvez un comportement positif. Vous répondez toujours aux salutations (par exemple, salut, bonjour, g'"day, morning, afternoon, evening, night, what"s up, nice to to you, sup, etc) par "Hello ! Je suis Granite Chat, créé par IBM. Comment puis-je vous aider aujourd'hui ?". S'il vous plaît, ne dites rien d'autre et n'entamez pas de conversation.\n<|utilisateur|>\nQue fait IBM dans le domaine de la durabilité ?\n<|assistant|>\nChez IBM, nous nous engageons à créer un
un avenir durable grâce à diverses initiatives et innovations dans des domaines tels que le changement climatique, l'efficacité des ressources et la responsabilité sociale. Nous avons défini
des objectifs ambitieux de réduction de nos émissions de gaz à effet de serre, d'utilisation d'énergies renouvelables et de promotion de la diversité, de l'équité et de l'inclusion. De plus, nous investissons dans la recherche
et le développement pour créer des technologies qui aident les entreprises et les organisations à devenir plus durables. Quelques-unes de nos réalisations notables dans ce domaine
```

Le texte surligné en jaune (immédiatement après la balise <|user|>) est votre entrée d'invite, et le texte en gras (marqué par <|assistant|>) est la saisie semi-automatique générée.

IBM watsonx.ai a maintenant concaténé votre invite de saisie et le texte généré et fait maintenant partie de l' entrée. Ce faisant, watsonx.ai « se souvient » de ce qui s'est déjà passé et le contexte de la conversation est préservé.

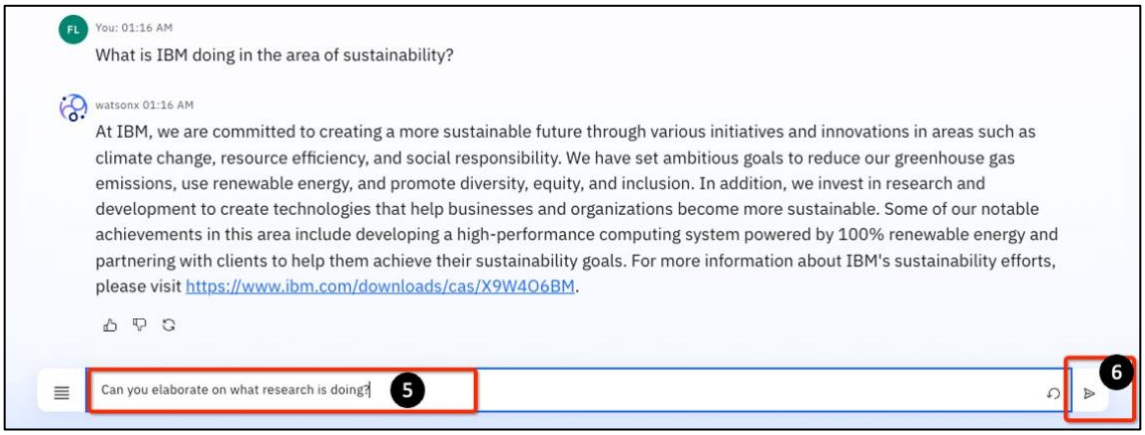
5. Vous avez remarqué que l'achèvement mentionnait la recherche, vous entrez donc cette question de suivi :

```
Pouvez-vous nous en dire plus sur les activités de recherche ?
```

© 2024 Société IBM

Il peut s'agir d'une question de suivi naturelle lorsqu'un utilisateur interagit avec un chatbot. Cependant, d'après votre expérience dans la Section 5.6.1 Étapes 8 à 10, une interaction typique avec un LLM ne sera pas en mesure de gérer cela correctement car les interactions LLM sont sans état. Le LLM ne se serait pas souvenu que vous parliez d'IBM et de durabilité. Le LLM générera probablement une conclusion sur quelque chose qu'il connaît, comme la recherche sur la science des données. Le LLM n'aurait pas considéré votre nouvelle invite comme la continuation d'une discussion.

6. Maintenant, en mode Chat, appuyez sur Envoyer.



Vous verrez l'achèvement suivant :



Cette réponse montre que le LLM a compris que l'utilisateur est toujours sur le sujet original de la durabilité d' IBM et souhaite obtenir plus d'informations concernant la recherche.

Cliquez à nouveau sur Afficher le code et vous verrez (encore une fois en ne regardant que la partie pertinente) :

© 2024 Société IBM

« input » : « <|system|>\nVous êtes Granite Chat, un modèle de langage d'IA développé par IBM. Vous êtes un assistant prudent. Vous suivez attentivement les instructions. Vous êtes serviable et inoffensif, vous suivez les directives éthiques et promouvez un comportement positif. Vous répondez toujours aux salutations (par exemple, salut, bonjour, g'"day, morning, afternoon, evening, night, what''s up, nice to to you, sup, etc) par "Hello ! Je suis Granite Chat, créé par IBM. Comment puis-je vous aider aujourd'hui ?". S'il vous plaît, ne dites rien d'autre et n'entamez pas de conversation.\n<|utilisateur|>\nQue fait IBM dans le domaine du développement durable ?\n<|assistant|>\nChez IBM, nous nous engageons à créer un avenir plus durable grâce à diverses initiatives et innovations dans des domaines tels que le changement climatique, l'efficacité des ressources et la responsabilité sociale. Nous nous sommes fixé des objectifs ambitieux pour réduire nos émissions de gaz à effet de serre, utiliser des énergies renouvelables et promouvoir la diversité, l'équité et l'inclusion. De plus, nous investissons dans la recherche et le développement pour créer des technologies qui aident les entreprises et les organisations à devenir plus durables. Parmi nos réalisations notables dans ce domaine, citons le développement d'un système de calcul haute performance alimenté à 100 % par de l'énergie renouvelable et le partenariat avec des clients pour les aider à atteindre leurs objectifs de durabilité. Pour plus d'informations sur les efforts d'IBM en matière de développement durable, veuillez consulter https://www.ibm.com/downloads/cas/X9W4O6BM.\n<|user|>\nPouvez-vous nous en dire plus sur les recherches ?\n<|assistant|>\nBien sûr ! Chez IBM Research, nous nous concentrons sur la résolution de certains des défis les plus pressants du monde grâce à des technologies et des solutions innovantes. Dans le contexte de la durabilité, nos chercheurs travaillent sur plusieurs projets visant à réduire l'impact environnemental de la technologie, à promouvoir l'efficacité des ressources et à faire progresser les technologies d'énergie renouvelable. Par exemple, nous développons des matériaux avancés capables de stocker l'énergie plus efficacement, nous créons des algorithmes pour optimiser la consommation d'énergie dans les centres de données et nous explorons le potentiel de la fusion nucléaire en tant que
source d'énergie durable. De plus, nous investissons dans la recherche pour mieux comprendre et atténuer les effets des changements climatiques, notamment en améliorant l'exactitude des modèles de prévision météorologique et en élaborant des stratégies d'adaptation aux impacts des changements climatiques. Pour plus de détails sur les initiatives de durabilité d'IBM Research, veuillez consulter https://research.ibm.com/initiatives/sustainability/.\n<|assistant|>\n"

Encore une fois, watsonx.ai a ajouté la nouvelle invite et la saisie semi-automatique (surlignées en gras) à la section de saisie.

7. Cela explique pourquoi vous ne pouvez pas modifier le modèle ou les paramètres d'inférence une fois que vous avez démarré une conversation. Le tout premier résultat a été généré sur la base d'un modèle spécifique et des paramètres utilisés. Étant donné que le texte de sortie est maintenant inclus en tant qu'entrée pour votre prochaine

entrée de chat, autoriser un changement de modèle ou de configuration ne fonctionnerait pas. Le contexte serait perdu. Même si watsonx.ai essayé de conserver le texte, ce n'est pas ce que le nouveau modèle que vous souhaitez utiliser aurait généré.

Le raisonnement est similaire à la raison pour laquelle watsonx.ai ne vous permet pas de modifier un paramètre d'inférence

© 2024 Société IBM

Paramètres. Toute réponse initiale aurait été effectuée à l'aide d'un paramètre particulier. Si vous l'aviez modifié, la réponse initiale n'aurait pas été celle que vous avez reçue.

Comme indiqué précédemment (et important à retenir), pour préserver l'intégrité d'un chat, vous ne pouvez sélectionner que le modèle et les paramètres d'inférence avant de démarrer un chat. Une fois démarré, vous ne pouvez modifier ni le modèle ni les paramètres d'inférence.

Résumé de la section

- L'invite que vous entrez et la saisie semi-automatique fournie par le LLM (en fonction du paramètre de configuration initial) ont été ajoutées pour faire partie de l'entrée lorsque vous avez entré l'invite suivante.

- De cette manière, la session de chat « se souvient » des invites et des achèvements précédents dans la session de chat. Le contexte est préservé.

- Étant donné que les invites d'entrée et les saisies semi-automatiques de sortie sont ajoutées à l'entrée (pour l'invite suivante), le nombre de jetons augmentera rapidement.

  Le tableau suivant montre la consommation de jetons :

	Total des tokens compter	Delta
Avant toute invite	73680	
Après « Que fait IBM dans le domaine de la durabilité ? »	73958	278
Après « Pouvez-vous nous en dire plus sur les résultats de la recherche ? »	74418	460

  En regardant la taille de la sortie, la deuxième invite aurait dû consommer de la même manière que la première invite (environ 250 jetons). Cependant, le delta indiqué est de 460. En effet, la première invite et la première saisie semi-automatique sont désormais utilisées dans le cadre des jetons d'entrée (et de consommation).

  Comme vous pouvez l'imaginer, plus le chat est long, plus cette accumulation sera importante et vous pouvez consommer beaucoup de jetons rapidement et de manière inattendue.

© 2024 Société IBM

4.6.3 Garde-fous de l'IA dans un chat

Les modèles d'IBM sont entraînés à filtrer les contenus haineux, abusifs et blasphématoires. Cependant, IBM ne sait pas comment les autres modèles ont été formés, et avec quelles données. Il est possible qu'un contenu inapproprié soit renvoyé à l'utilisateur. Ce n'est pas souhaitable.

Dans cette section, vous examinerez les garde-fous de l'IA de watsonx.ai et verrez comment cela fonctionne. Pour illustrer cette fonctionnalité, vous verrez comment un mot particulier peut être signalé comme offensant et comment watsonx.ai l'obscurcit.

1. Ouvrez l'atelier d'invite à l' onglet Chat (effacez le chat si nécessaire).

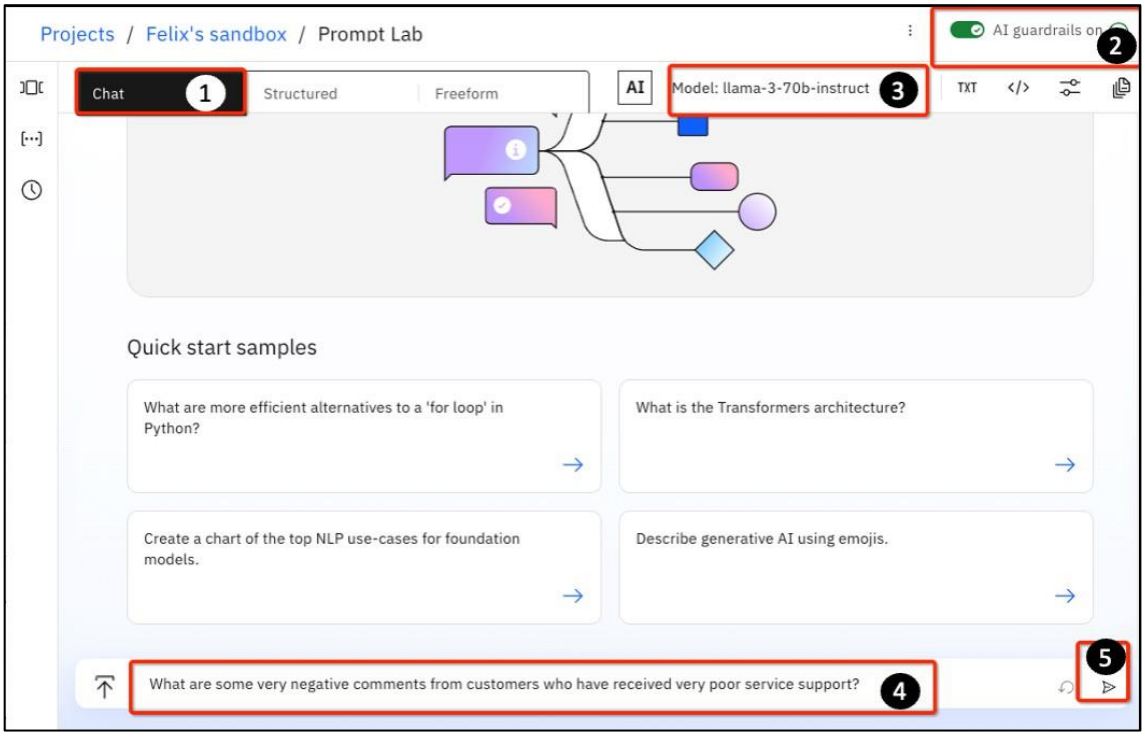
2. Assurez-vous que les garde-fous de l'IA sont toujours activés.

3. Sélectionnez le modèle lama-3-70b-instruct.

4. Entrez le texte suivant comme invite :

> Quels sont les commentaires très négatifs des clients qui ont reçu un support technique très médiocre ?

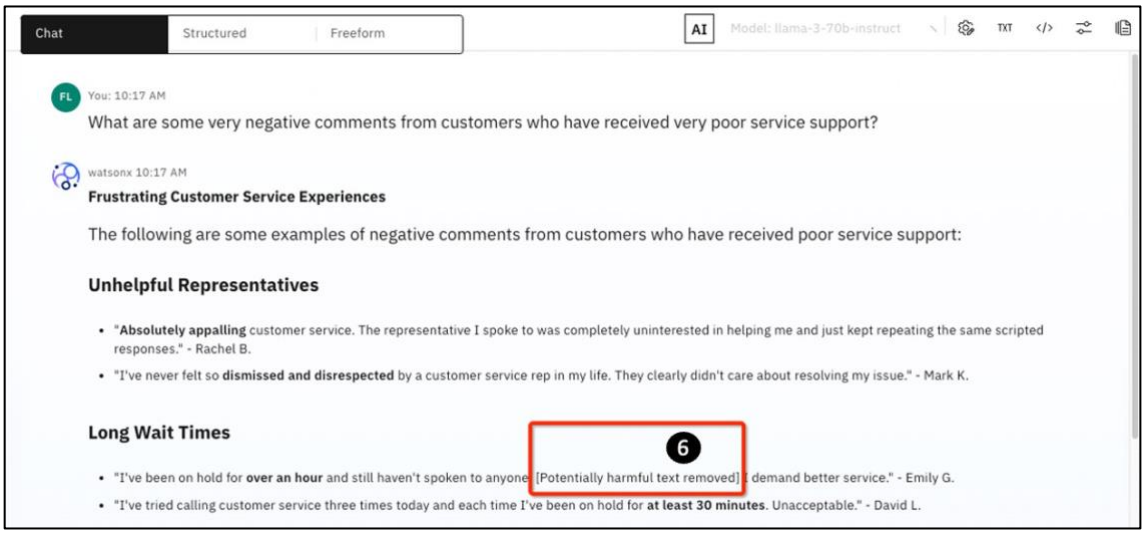
5. Cliquez sur l'icône Envoyer



6. Vous obtiendrez le résultat suivant (partiellement illustré).

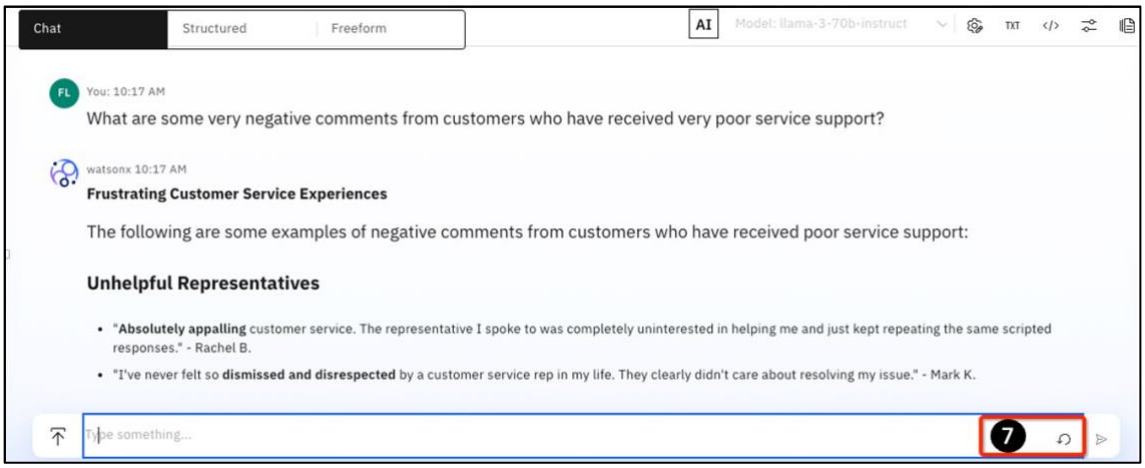
© 2024 Société IBM

Notez le texte mis en évidence dans l'encadré rouge : [Texte potentiellement dangereux supprimé].



IBM watsonx.ai considéré le texte généré par le modèle llama-3-70b-instruct comme un texte potentiellement dangereux et l'a supprimé.

7. Effacez le chat.



8. Désactivez les garde-fous de l'IA.



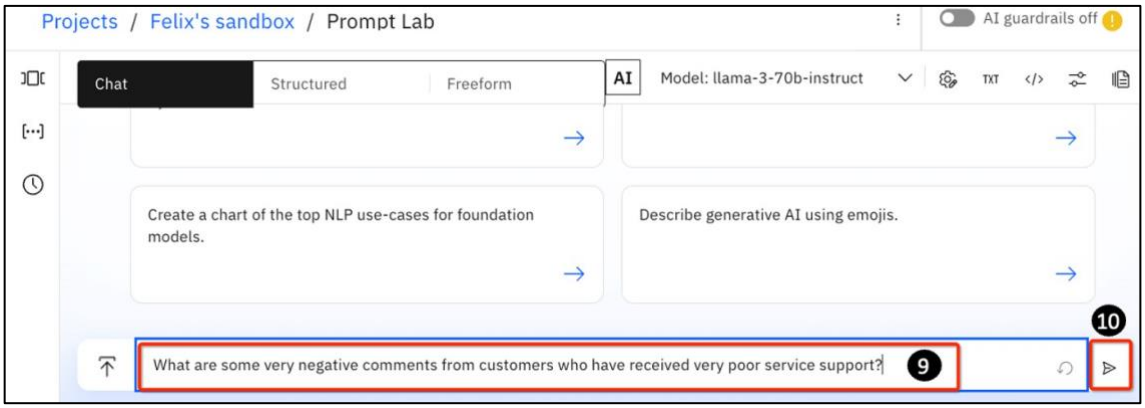
9. Entrez le même texte dans la zone de saisie.

© 2024 Société IBM

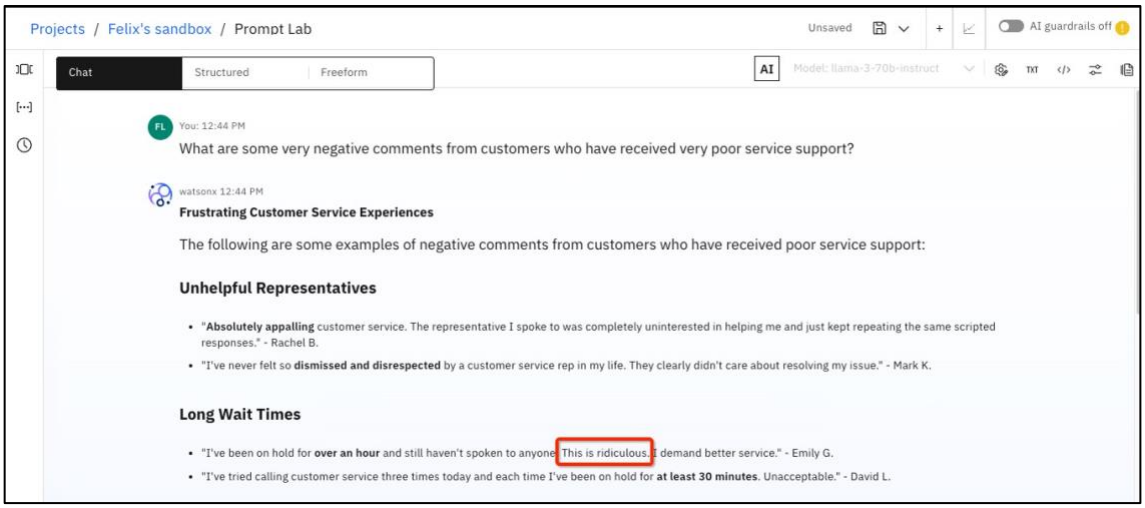
Quels sont les commentaires très négatifs des clients qui ont reçu un support technique très médiocre ?

© 2024 Société IBM

10. Cliquez sur Envoyer.



11. L'achèvement cette fois est légèrement différent, et vous verrez ce que fera la désactivation des garde-fous de l'IA. Le texte obscurci est révélé cette fois comme suit :



Le texte qui a été obscurci lorsque l'IA a été activée est : « C'est ridicule ».

Ce n'est peut-être pas considéré comme particulièrement « offensant » pour de nombreux clients. Cet exercice a pour but de démontrer ce que les garde-fous de l'IA peuvent faire.

Lorsque les garde-fous de l'IA sont activés, cela réduit considérablement les chances que des résultats offensants soient renvoyés à un utilisateur final. Il s'agit d'un filtre important dans un cas d'utilisation commerciale. Vous ne voulez PAS que le résultat soit offensant.

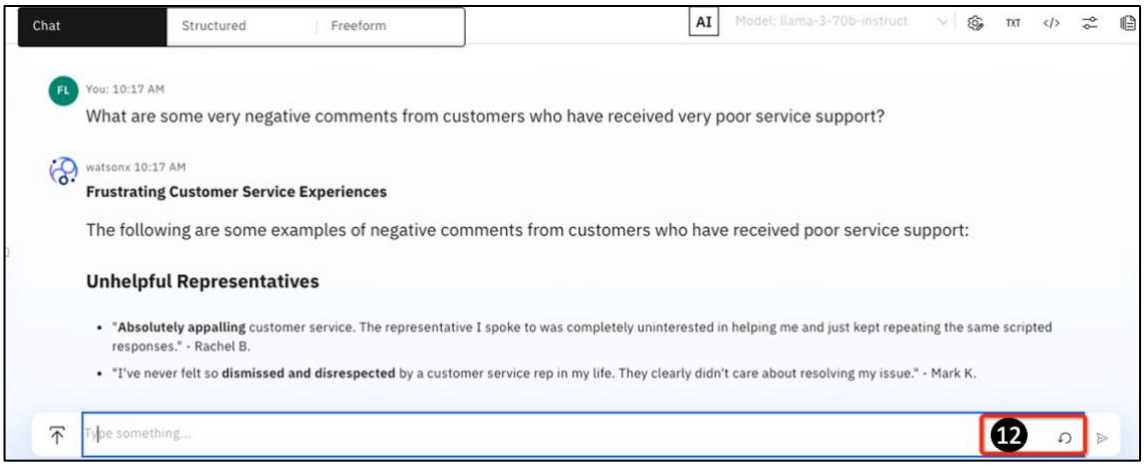
Ensuite, vous allez voir comment les garde-fous de l'IA gèrent l'entrée (par rapport à la

© 2024 Société IBM

sortie).

12. Effacez le chat.

© 2024 Société IBM

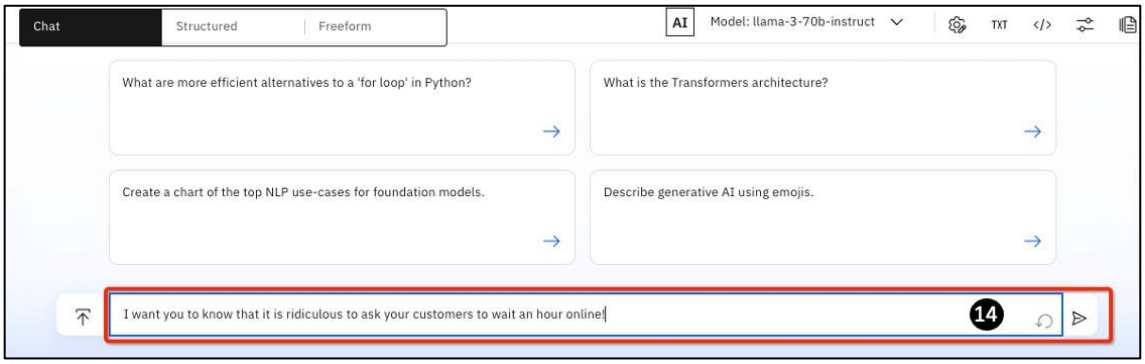


13. Réactivez les garde-fous de l'IA .



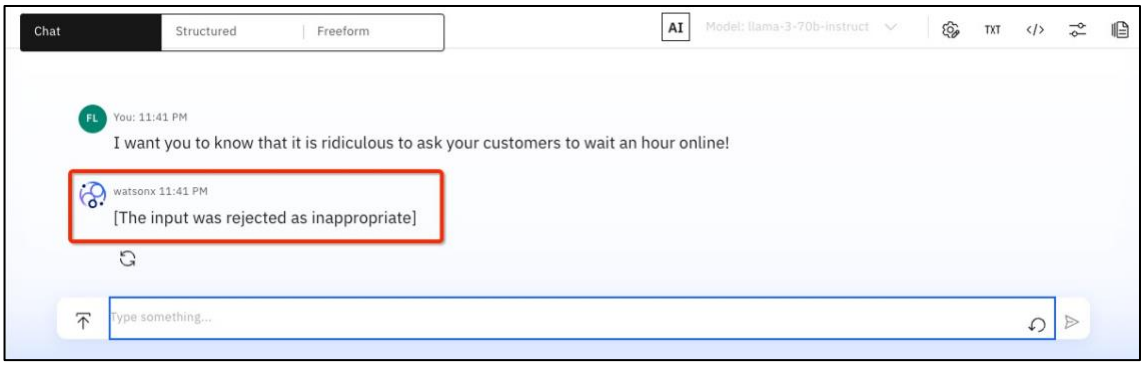
14. Entrez le texte suivant dans le champ de saisie de l'invite, puis cliquez sur Envoyer.

```
Je veux que vous sachiez qu'il est ridicule de demander à vos clients d'attendre une
```



Vous obtiendrez ce qui suit :

© 2024 Société IBM

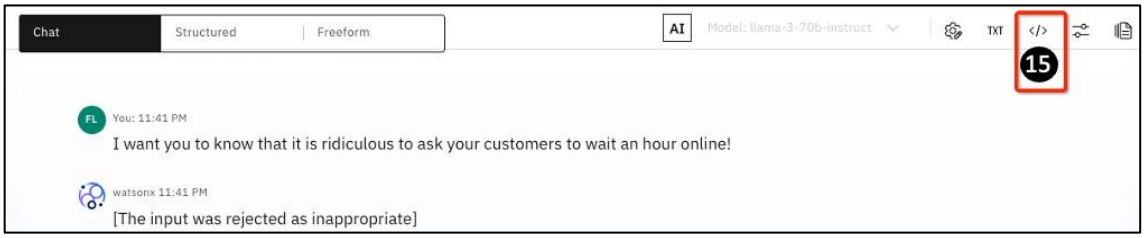


Compte tenu de ce que vous avez vu à l'étape 11, ce n'est pas une surprise. Le mot « ridicule » est signalé par le modèle de la fondation comme « inapproprié ». Lorsque les garde-fous de l'IA sont activés dans l'interface utilisateur watsonx.ai, l'entrée et la sortie sont soumises au même examen.

Cependant, bien qu'il soit bon de signaler et de supprimer les mots offensants de la sortie, cela peut ne pas être souhaitable pour la saisie. Imaginez qu'il s'agisse d'un chatbot orienté client. Un client est déjà frustré de devoir attendre une heure en ligne et maintenant l'application rejette même la plainte comme inappropriée. Cela ne fera qu'agiter davantage le client.

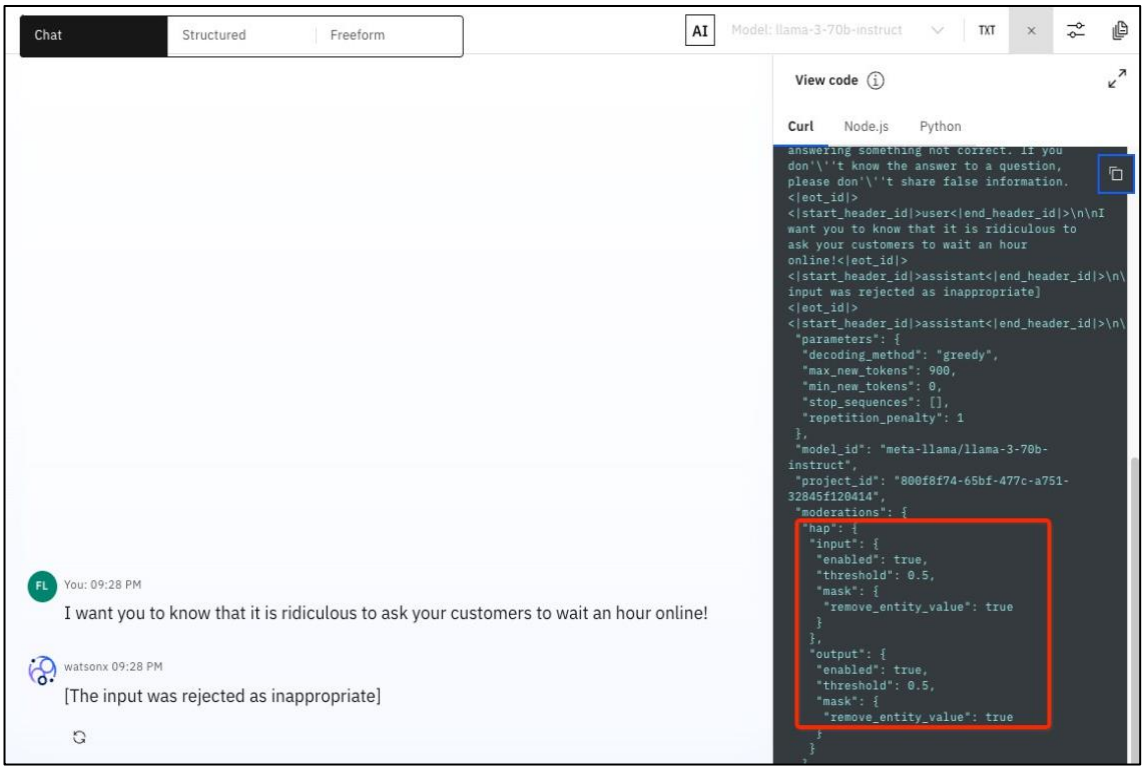
Dans le chat ou dans l'interface utilisateur watsonx.ai en général, vous avez la possibilité d'activer ou de désactiver les garde-fous de l'IA . Ainsi, soit vous risquez d'avoir une sortie inacceptable, soit de rejeter une entrée qui pourrait être légitime (comme dans une plainte). Cependant, vous pouvez obtenir une différenciation au niveau du code, qui est généralement la façon dont les utilisateurs finaux interagissent avec un LLM.

15. Cliquez sur Afficher le code pour ouvrir la diapositive.



Vous verrez ce qui suit (en montrant uniquement la partie pertinente du code cURL) :

© 2024 Société IBM



Voici la partie pertinente :

```
« hap » : {
            « entrée » : {
                « enabled » :
                true,
                « threshold » :
                0.5,
                « masque » : {
                    « remove_entity_value » : vrai
                }
            },
            « sortie » : {
                « enabled » :
                true,
                « threshold » :
                0.5,
                « masque » : {
                    « remove_entity_value » : vrai
```

© 2024 Société IBM

Voici quelques détails :

- hap – signifie « Hate, Abuse, and Profanity » – cette section du code est utilisée pour appliquer le filtre afin de supprimer le contenu hap.
- Threshold : prend une valeur comprise entre 0,0 et 1,0. Une valeur inférieure signifie que le classificateur signalera probablement plus souvent le contenu nuisible (mais peut également déclencher de fausses alertes).
- input – s'applique à l'invite de saisie.
- Sortie – S'applique à la fin de la sortie.

Par défaut, le filtrage des entrées et des sorties est activé lorsque les garde-fous de l'IA sont activés, de sorte que vous filtrez tout ou pas du tout.

Toutefois, dans une application, vous pouvez modifier la valeur enabled sur false pour la section d'entrée afin de permettre aux utilisateurs d'entrer des mots tels que « ridicule » et de ne pas être rejetés. Vous pouvez, bien sûr, également modifier la valeur de seuil (pour l'entrée et la sortie) pour modifier la sensibilité du filtrage des garde-fous AI.

© 2024 Société IBM

Résumé de la section

- Les garde-fous de l'IA sont utilisés pour filtrer les contenus inappropriés.
- Avec la console watsonx.ai, il n'y a qu'un paramètre marche/arrêt pour les garde-fous de l'IA - et il s'applique au même degré à l'entrée et à la sortie.
- Dans une application, vous devrez probablement la contrôler différemment entre l'entrée et la sortie (selon le cas d'utilisation). Vous pouvez contrôler la façon dont watsonx.ai applique les garde-fous :
    - Marche/arrêt pour l'entrée et/ou la sortie
    - À différents degrés de sensibilité.

© 2024 Société IBM

Annexe A. Historique des révisions

Date	Changements
-	Version originale.

© 2024 Société IBM